



# Отчет о проверке


Автор: Kobzar Alexander

Проверяющий: Kobzar Alexander

Название документа: diplom\_kobzar (1)

## РЕЗУЛЬТАТЫ ПРОВЕРКИ

Тариф: FULL



Совпадения:  
1,45%



Оригинальность:  
97,88%



ИИ-контент:  
16,01%



Цитирования:  
0,67%



Самоцитирования:  
0%



«Совпадения», «Цитирования», «Самоцитирования», «Оригинальность» являются отдельными показателями, отображаются в процентах и в сумме дают 100%, что соответствует проверенному тексту документа.

Есть подозрения на следующие группы маскировки заимствований: Сгенерированный текст на страницах: 3, 4, 10, 11, 12, 13, 14, 18, 19, 20... еще на 8 стр.

Проверено: 92,55% текста документа, исключено из проверки: 7,45% текста документа. Разделы и элементы, отключенные пользователем: Библиография, Таблицы

- Совпадения** — фрагменты проверяемого текста, полностью или частично сходные с найденными источниками, за исключением фрагментов, которые система отнесла к цитированию или самоцитированию. Показатель «Совпадения» — это доля фрагментов проверяемого текста, отнесенных к совпадениям, в общем объеме текста.
- Самоцитирования** — фрагменты проверяемого текста, совпадающие или почти совпадающие с фрагментом текста источника, автором или соавтором которого является автор проверяемого документа. Показатель «Самоцитирования» — это доля фрагментов текста, отнесенных к самоцитированию, в общем объеме текста.
- Цитирования** — фрагменты проверяемого текста, которые не являются авторскими, но которые система отнесла к корректно оформленным. К цитированиям относятся также шаблонные фразы; библиография; фрагменты текста, найденные модулем поиска «СПС Гарант: нормативно-правовая документация». Показатель «Цитирования» — это доля фрагментов проверяемого текста, отнесенных к цитированию, в общем объеме текста.
- Текстовое пересечение** — фрагмент текста проверяемого документа, совпадающий или почти совпадающий с фрагментом текста источника.
- Источник** — документ, проиндексированный в системе и содержащийся в модуле поиска, по которому проводится проверка.
- Оригинальный текст** — фрагменты проверяемого текста, не обнаруженные ни в одном источнике и не отмеченные ни одним из модулей поиска. Показатель «Оригинальность» — это доля фрагментов проверяемого текста, отнесенных к оригинальному тексту, в общем объеме текста.

Обращаем Ваше внимание, что система находит текстовые совпадения проверяемого документа с проиндексированными в системе источниками. При этом система является вспомогательным инструментом, определение корректности и правомерности совпадений или цитирований, а также авторства текстовых фрагментов проверяемого документа остается в компетенции проверяющего.

## ИНФОРМАЦИЯ О ДОКУМЕНТЕ

Номер документа: 4

Тип документа: Не указано

Дата проверки: 25.05.2026 02:05:25

Дата корректировки: Нет

Количество страниц: 61

Символов в тексте: 117316

Слов в тексте: 14272

Число предложений: 1062

**Комментарий:** не указано

## ПАРАМЕТРЫ ПРОВЕРКИ

Выполнена проверка с учетом редактирования: Да

Выполнено распознавание текста (OCR): Нет

Выполнена проверка с учетом структуры: Да

Разделы и элементы, отключенные пользователем: Библиография, Таблицы

**Модули поиска:** Профессиональная лексика. Медицина, Цитирование, Патенты СССР, РФ, СНГ, Перефразированные заимствования по коллекции Интернет в английском сегменте, Профессиональная лексика. АПК и биотех, Шаблонные фразы, Переводные заимствования, Перефразирования по Коллекции открытых публикаций международных издательств, ИПС Адилет, Профессиональная лексика. Юриспруденция, Перефразирования по коллекции IEEE, Перефразирования по базе публикаций открытого доступа PubMed, Коллекция НБУ, Сводная коллекция научных работ Беларуси, Рувик, Сводная коллекция ЭБС, СМИ России и СНГ, IEEE, Кольцо вузов, PubMed, Медицина, СПС ГАРАНТ: нормативно-правовая документация, Публикации eLIBRARY, Публикации РГБ (переводы и перефразирования), Публикации РГБ, СПС ГАРАНТ: аналитика, Кольцо вузов (переводы и перефразирования), Коллекция открытых публикаций международных издательств, Переводные заимствования по коллекции Гарант: аналитика, Публикации eLIBRARY (переводы и перефразирования), Перефразирования по СПС ГАРАНТ: аналитика, Переводные заимствования IEEE, Переводные заимствования по коллекции Интернет в английском сегменте, Переводные заимствования по Коллекции открытых публикаций международных издательств, Переводные заимствования по базе публикаций открытого доступа PubMed, Перефразированные заимствования по коллекции Интернет в русском сегменте, Переводные заимствования по коллекции Интернет в русском сегменте, Интернет Плюс

## ИСТОЧНИКИ

| №    | Доля в тексте | Доля в отчете | Источник                                                                                                    | Актуален на | Модуль поиска                                                        | Комментарий                                                |
|------|---------------|---------------|-------------------------------------------------------------------------------------------------------------|-------------|----------------------------------------------------------------------|------------------------------------------------------------|
| [01] | 0,67%         | 0,67%         | не указано                                                                                                  | 11 Мар 2026 | Шаблонные фразы                                                      |                                                            |
| [02] | 0,57%         | 0,09%         | Инвестиции: оценка, отраслевые...<br><a href="http://elibrary.ru">http://elibrary.ru</a>                    | 01 Янв 2021 | Публикации eLIBRARY                                                  |                                                            |
| [03] | 0,52%         | 0,17%         | КОРПОРАТИВНАЯ ПУБЛИЧНАЯ О...<br><a href="https://openalex.org">https://openalex.org</a>                     | 10 Ноя 2022 | Коллекция открытых публикаций международных издательств              |                                                            |
| [04] | 0,45%         | 0,22%         | «Цифровое приложение для авто...<br><a href="https://fips.ru">https://fips.ru</a>                           | 04 Апр 2026 | Патенты СССР, РФ, СНГ                                                |                                                            |
| [05] | 0,45%         | 0%            | Консолидированная финансовая...<br><a href="https://ru.ruwiki.ru">https://ru.ruwiki.ru</a>                  | 22 Фев 2026 | Рувик                                                                |                                                            |
| [06] | 0,45%         | 0%            | Детали. Как получать сведения и...<br><a href="http://gorodskoyportal.ru">http://gorodskoyportal.ru</a>     | 03 Ноя 2020 | СМИ России и СНГ                                                     |                                                            |
| [07] | 0,44%         | 0%            | Годовой отчёт 2022. Бухгалтерск...<br><a href="http://ivo.garant.ru">http://ivo.garant.ru</a>               | 24 Дек 2022 | СПС ГАРАНТ: аналитика                                                |                                                            |
| [08] | 0,42%         | 0%            | Развитие учетно-аналитического...<br><a href="https://elib.nlb.by">https://elib.nlb.by</a>                  | 01 Янв 2009 | Сводная коллекция научных работ Беларуси                             |                                                            |
| [09] | 0,41%         | 0%            | Бухгалтерский и налоговый учет ...<br><a href="http://dlib.rsl.ru">http://dlib.rsl.ru</a>                   | 01 Янв 2014 | Публикации РГБ                                                       |                                                            |
| [10] | 0,41%         | 0%            | Бухгалтерский и налоговый учет ...<br><a href="https://vital.lib.tsu.ru">https://vital.lib.tsu.ru</a>       | 07 Мар 2023 | Интернет Плюс                                                        |                                                            |
| [11] | 0,4%          | 0%            | ignatev_d_a_ocenka-investicionnoy...                                                                        | 15 Мая 2026 | Кольцо вузов                                                         | Источник исключен. Причина: Маленький процент пересечения. |
| [12] | 0,35%         | 0,03%         | Косорукова И.В., Секачев С.А., Шу...<br><a href="http://ivo.garant.ru">http://ivo.garant.ru</a>             | 20 Фев 2016 | Перефразирования по СПС ГАРАНТ: аналитика                            |                                                            |
| [13] | 0,34%         | 0%            | Решения единственного акционе...<br><a href="http://e-disclosure.azipi.ru">http://e-disclosure.azipi.ru</a> | 20 Июн 2016 | СМИ России и СНГ                                                     |                                                            |
| [14] | 0,34%         | 0%            | Бухгалтерская (финансовая) отчет...<br><a href="http://elibrary.ru">http://elibrary.ru</a>                  | 01 Янв 2017 | Публикации eLIBRARY                                                  |                                                            |
| [15] | 0,34%         | 0%            | Семенихин В.В. Годовой отчет за...<br><a href="http://ivo.garant.ru">http://ivo.garant.ru</a>               | 12 Янв 2019 | СПС ГАРАНТ: аналитика                                                | Источник исключен. Причина: Маленький процент пересечения. |
| [16] | 0,32%         | 0%            | Учет и контроль формирования с...<br><a href="https://elib.nlb.by">https://elib.nlb.by</a>                  | 01 Янв 2012 | Сводная коллекция научных работ Беларуси                             |                                                            |
| [17] | 0,32%         | 0,32%         | URSS.ru - Comprar libro: Кузнецов ...<br><a href="http://urss.ru">http://urss.ru</a>                        | 02 Апр 2015 | Переводные заимствования по коллекции Интернет в английском сегменте |                                                            |
| [18] | 0,32%         | 0,32%         | petrov_n_d_obnaruzhenie-setevyh-at...                                                                       | 12 Мая 2026 | Кольцо вузов (переводы и                                             |                                                            |

|      |       |      |                                                                                                           |              |                                                 |                                                            |
|------|-------|------|-----------------------------------------------------------------------------------------------------------|--------------|-------------------------------------------------|------------------------------------------------------------|
|      |       |      |                                                                                                           |              | перепаразирования)                              |                                                            |
| [19] | 0,3%  | 0,3% | ВКР_Кондратьев А.Д_ММН-24-1                                                                               | 20 Мая 2026  | Кольцо вузов<br>(переводы и перепаразирования)  |                                                            |
| [20] | 0,3%  | 0%   | ВКР 2017 ОЦЕНКА ФИНАНСОВЫХ ...                                                                            | 15 Янв 2024  | Кольцо вузов                                    | Источник исключен. Причина: Маленький процент пересечения. |
| [21] | 0,3%  | 0%   | Бухгалтерский учет. Интенсивны...                                                                         | 19 Дек 2016  | Медицина                                        | Источник исключен. Причина: Маленький процент пересечения. |
| [22] | 0,25% | 0%   | Бухгалтерская (финансовая) отчете...<br><a href="https://buh.ru">https://buh.ru</a>                       | 17 Авг 2019  | СМИ России и СНГ                                |                                                            |
| [23] | 0,25% | 0%   | Анализ баланса   part#1<br><a href="http://studentlibrary.ru">http://studentlibrary.ru</a>                | 19 Дек 2016  | Медицина                                        |                                                            |
| [24] | 0,25% | 0%   | Ковалев В.В., Ковалев Вит.В. Кор...<br><a href="http://ivo.garant.ru">http://ivo.garant.ru</a>            | 17 Авг 2019  | СПС ГАРАНТ:<br>аналитика                        |                                                            |
| [25] | 0,23% | 0%   | Чепулянис А.В._Комплексный фи...                                                                          | 14 Янв 2024  | Кольцо вузов                                    | Источник исключен. Причина: Маленький процент пересечения. |
| [26] | 0,2%  | 0%   | Бухгалтерский учет финансовых ...<br><a href="https://elib.nlb.by">https://elib.nlb.by</a>                | 01 Янв 2004  | Сводная коллекция научных работ<br>Беларуси     | Источник исключен. Причина: Маленький процент пересечения. |
| [27] | 0,2%  | 0%   | О требовании существенности в ...<br><a href="http://gaap.ru">http://gaap.ru</a>                          | 30 Мар 2016  | СМИ России и СНГ                                | Источник исключен. Причина: Маленький процент пересечения. |
| [28] | 0,2%  | 0%   | 14 Отчетность                                                                                             | 20 Фев 2025  | Кольцо вузов                                    | Источник исключен. Причина: Маленький процент пересечения. |
| [29] | 0,2%  | 0%   | Бухгалтерский учет: учебно-прак...                                                                        | 19 Дек 2016  | Медицина                                        | Источник исключен. Причина: Маленький процент пересечения. |
| [30] | 0,2%  | 0%   | Решение Совета директоров ОА...<br><a href="http://ivo.garant.ru">http://ivo.garant.ru</a>                | 08 Авг 2015  | СПС ГАРАНТ:<br>нормативно-правовая документация | Источник исключен. Причина: Маленький процент пересечения. |
| [31] | 0,2%  | 0%   | Приказ Минфина России от 4 окт...<br><a href="http://ivo.garant.ru">http://ivo.garant.ru</a>              | 25 Мар 2024  | СПС ГАРАНТ:<br>нормативно-правовая документация | Источник исключен. Причина: Маленький процент пересечения. |
| [32] | 0,2%  | 0%   | Решение Совета директоров ПА...<br><a href="http://ivo.garant.ru">http://ivo.garant.ru</a>                | 03 Авг 2016  | СПС ГАРАНТ:<br>нормативно-правовая документация | Источник исключен. Причина: Маленький процент пересечения. |
| [33] | 0,2%  | 0%   | Проект Приказа Министерства ф...<br><a href="http://ivo.garant.ru">http://ivo.garant.ru</a>               | 11 Июнь 2023 | СПС ГАРАНТ:<br>нормативно-правовая документация | Источник исключен. Причина: Маленький процент пересечения. |
| [34] | 0,2%  | 0%   | В. В. Семенихин Годовой отчет 2...<br><a href="http://dlib.rsl.ru">http://dlib.rsl.ru</a>                 | 01 Дек 2014  | Публикации РГБ                                  | Источник исключен. Причина: Маленький процент пересечения. |
| [35] | 0,2%  | 0%   | Крутякова Т.Л. Годовой отчет 201...<br><a href="http://ivo.garant.ru">http://ivo.garant.ru</a>            | 01 Фев 2020  | СПС ГАРАНТ:<br>аналитика                        | Источник исключен. Причина: Маленький процент пересечения. |
| [36] | 0,18% | 0%   | Стратегия развития бухгалтерско...<br><a href="https://elib.nlb.by">https://elib.nlb.by</a>               | 01 Янв 2012  | Сводная коллекция научных работ<br>Беларуси     | Источник исключен. Причина: Маленький процент пересечения. |
| [37] | 0,18% | 0%   | Молдобаев, Темирлан Шайырбек...<br><a href="http://dlib.rsl.ru">http://dlib.rsl.ru</a>                    | 01 Янв 2025  | Публикации РГБ                                  | Источник исключен. Причина: Маленький процент пересечения. |
| [38] | 0,15% | 0%   | 65905<br><a href="http://e.lanbook.com">http://e.lanbook.com</a>                                          | 09 Мар 2016  | Сводная коллекция ЭБС                           | Источник исключен. Причина: Маленький процент пересечения. |
| [39] | 0,15% | 0%   | Анализ финансовой отчетности<br><a href="https://e.lanbook.com">https://e.lanbook.com</a>                 | 22 Янв 2020  | Сводная коллекция ЭБС                           | Источник исключен. Причина: Маленький процент пересечения. |
| [40] | 0,14% | 0%   | Анализ финансовой отчетности<br><a href="https://geotar.ru">https://geotar.ru</a>                         | 26 Мая 2021  | Сводная коллекция ЭБС                           | Источник исключен. Причина: Маленький процент пересечения. |
| [41] | 0,14% | 0%   | Анализ финансовой отчетности<br><a href="https://geotar.ru">https://geotar.ru</a>                         | 03 Дек 2020  | Сводная коллекция ЭБС                           | Источник исключен. Причина: Маленький процент пересечения. |
| [42] | 0,13% | 0%   | Косорукова И.В., Секачев С.А., Шу...<br><a href="http://ivo.garant.ru">http://ivo.garant.ru</a>           | 20 Фев 2016  | СПС ГАРАНТ:<br>аналитика                        | Источник исключен. Причина: Маленький процент пересечения. |
| [43] | 0,11% | 0%   | Хисаметдинов, Фиргат Зайнулло...<br><a href="http://dlib.rsl.ru">http://dlib.rsl.ru</a>                   | 01 Янв 2019  | Публикации РГБ                                  | Источник исключен. Причина: Маленький процент пересечения. |
| [44] | 0,11% | 0%   | 2013.DSPA.Lukin_Storozhilova_Yuri...<br><a href="https://imaging.cs.msu.ru">https://imaging.cs.msu.ru</a> | 07 Июл 2025  | Интернет Плюс                                   | Источник исключен. Причина: Маленький процент пересечения. |
| [45] | 0,11% | 0%   | ФИНАНСОВЫЙ АНАЛИЗ. Учебник...                                                                             | 22 Фев 2017  | Сводная коллекция ЭБС                           | Источник исключен. Причина: Маленький процент пересечения. |

Московский государственный университет имени М.В. Ломоносова

Факультет вычислительной математики и кибернетики

Лаборатория открытых информационных технологий



Выпускная квалификационная работа

«Применение методов машинного обучения для оценки  
финансового состояния компаний»

Выполнил студент 4 курса ВВО бакалавриата

Кобзарь А.А.

Научный руководитель:

В.В. Прусаков,

программист лаборатории

открытых информационных технологий

Москва, 2026

## Содержание

### Введение3

1. Объект, предмет, цели и задачи исследования.3
2. Описание данных.4
  - 2.1. Источники.5
  - 2.2. Целевая переменная.8
  - 2.3. Признаки.8
3. Обзор литературы12

### Глава I. Описание методов машинного обучения для анализа финансовой отчетности17

### Глава II. Программная реализация и экспериментальные результаты.29

#### Экспериментальные результаты и выводы.41

### Заключение48

### Литература54

### Приложение58

1. Ссылка на программную реализацию58
2. Признаки, используемые в обучении моделей58
3. Важность признаков60
4. Метрики качества61

## Введение

В современных условиях компании раскрывают всё больше финансовой и корпоративной информации. При этом от управленческих решений требуется не только оперативность, но и более высокая степень обоснованности. Поэтому анализ финансовой отчётности всё чаще используется не только для оценки уже сложившегося положения компании, но и для прогнозирования её дальнейшего финансового состояния. Классические методы финансового анализа сохраняют практическое значение, поскольку дают понятные показатели ликвидности, рентабельности, долговой нагрузки и деловой активности. Однако такие методы обычно опираются на ограниченный набор коэффициентов и достаточно простые предположения о связи между ними. В реальных данных зависимости часто оказываются сложнее: влияние отдельных факторов может проявляться с задержкой, меняться в разные периоды и зависеть от сочетания нескольких показателей. Из-за этого традиционные подходы не всегда позволяют достаточно точно учитывать нелинейные эффекты и сложную структуру финансовых данных.

### 1. Объект, предмет, цели и задачи исследования

Объектом исследования является процесс анализа финансовой отчётности компаний при решении задач финансового прогнозирования и оценки риска. Предметом исследования являются методы машинного обучения, применяемые к данным финансовой отчётности и финансовым временным рядам. Кроме того, в работе рассматриваются процедуры отбора признаков и способы интерпретации вклада отдельных факторов в итоговый прогноз. Цель исследования состоит в разработке и обосновании подхода к анализу финансовой отчётности на основе методов машинного обучения. Такой подход должен быть направлен на повышение качества прогноза и одновременно сохранять возможность экономической интерпретации полученных результатов. Задачи исследования:

1. Проанализировать теоретические подходы к финансовому анализу отчетности и обосновать переход к ML-инструментам.
2. Реализовать процедуры отбора и сжатия признаков для снижения размерности и устранения избыточности факторов.
3. Построить и сравнить модели для задач регрессии и вероятностного прогноза.

4. Оценить качество моделей на данных по системе метрик точности и устойчивости.
5. Выполнить анализ значимости признаков после ансамблевых методов и дать экономическую интерпретацию полученных факторов.
6. Сформулировать практические рекомендации по применению выбранных моделей в анализе финансовой отчетности.

## 2. Описание данных

Финансовые данные, используемые в экономико-математическом моделировании и задачах машинного обучения, отличаются высокой неоднородностью по структуре, частоте обновления, источникам формирования и степени предварительной обработки. Для корректного построения моделей и интерпретации полученных результатов целесообразно выделять несколько ключевых типов финансовых данных.

Фундаментальные данные представляют собой количественные и качественные показатели, отражающие финансово-экономическое состояние компаний, отраслей и экономики в целом. Основным источником фундаментальных данных является регламентированная финансовая отчетность, формируемая в соответствии с национальными и международными стандартами (РСБУ, МСФО), а также макроэкономическая статистика. К фундаментальным данным в работе относятся показатели из основных форм финансовой отчетности: бухгалтерского баланса, отчёта о финансовых результатах и отчёта о движении денежных средств. <sup>1</sup>о, например, активы, обязательства, выручка, прибыль, капитальные затраты, показатели долга и другие близкие по смыслу величины. У таких данных есть важная особенность: они обновляются не каждый день, а обычно раз в квартал или раз в год. Кроме того, отчётность появляется не в момент окончания отчётного периода, а позже. Поэтому при построении модели важно учитывать дату фактического раскрытия данных. Если использовать показатель раньше, чем он стал доступен рынку, в выборке возникает смещение: модель как бы получает информацию из будущего. В результате качество прогноза на тесте может выглядеть лучше, чем оно было бы в реальной задаче. Есть и ещё один технический момент: финансовая отчётность иногда пересматривается или уточняется задним числом. Поэтому при



подготовке обучающих и тестовых выборок нужно аккуратно работать с версиями данных и следить, какие значения были доступны на конкретную дату. Иначе часть результата будет объясняться не качеством модели, а ошибкой в подготовке данных.

Рыночные данные отражают процесс ценообразования и торговой активности на финансовых рынках. К данному типу относятся цены финансовых инструментов, объемы торгов, доходности, котировки спроса и предложения, открытый интерес, а также производные показатели, такие как волатильность и спрэды. Рыночные данные характеризуются высокой частотой наблюдений — от дневных значений до тиковых данных, фиксирующих каждую сделку или изменение заявки в торговом стакане. В отличие от фундаментальных данных, рыночные данные не содержат временного лага публикации и доступны участникам рынка практически в реальном времени. С точки зрения прикладной математики и машинного обучения, рыночные данные представляют особый интерес благодаря большому объему наблюдений и возможности построения динамических и стохастических моделей. Вместе с тем высокая зашумленность и нестационарность временных рядов требуют применения специальных методов фильтрации, нормализации и регуляризации.<sup>1</sup>

В данной работе используются данные за период 2011–2024 гг. Выбор временного интервала обусловлен доступностью и сопоставимостью бухгалтерской (финансовой) отчетности российских компаний.

#### а. Источники

Для решения задачи оценки финансового состояния компаний методами машинного обучения в работе используются данные, полученные из нескольких взаимодополняющих источников. Применение различных информационных ресурсов обусловлено необходимостью одновременного учета как внутренних финансовых характеристик компаний, отражаемых в бухгалтерской отчетности, так и внешних рыночных оценок, характеризующих положение компании на финансовом рынке.

ПАО «Московская биржа» является основным организатором торгов на российском фондовом рынке и официальным источником информации о рыночных характеристиках

---

<sup>1</sup> López de Prado M. *Advances in financial machine learning* — Hoboken: Wiley, 2018. — ISBN 978-1-119-49036-9

публичных компаний. В рамках данной выпускной квалификационной работы <sup>1</sup> данные Московской биржи используются для формирования целевой переменной, отражающей рыночную капитализацию компаний. Информация о котировках акций, количестве выпущенных ценных бумаг, а также об изменениях в структуре капитала компаний публикуется Московской биржей на регулярной основе и характеризуется высокой степенью достоверности и актуальности. Наличие исторических данных позволяет формировать временные ряды рыночной капитализации и использовать их для анализа динамики финансового состояния компаний. Использование данных ПАО «Московская биржа» в качестве целевой переменной в моделях машинного обучения позволяет связать показатели бухгалтерской отчетности компаний с их рыночной оценкой, а также исследовать, в какой степени финансовые характеристики, отраженные в отчетности, объясняют различия в капитализации российских публичных компаний.<sup>2</sup>

Финансовая отчетность компаний, являющаяся основным источником признаков для моделей машинного обучения, формируется на основе данных Государственного информационного ресурса бухгалтерской отчетности Федеральной налоговой службы Российской Федерации (ГИР БО). Данный ресурс содержит бухгалтерскую (финансовую) отчетность компаний, представленную в соответствии с российскими стандартами бухгалтерского учета. Государственный информационный ресурс бухгалтерской отчетности ФНС России (ГИР БО) используется в работе как основной источник исходных данных о финансовых показателях российских компаний. Ресурс содержит бухгалтерскую отчетность организаций, представленную в соответствии с российскими стандартами бухгалтерского учета (РСБУ), <sup>3</sup> включая <sup>2</sup> бухгалтерский баланс и отчет о финансовых результатах. <sup>1</sup> До конца 2010-х годов сбор и хранение бухгалтерской отчетности осуществлялись органами государственной статистики (Росстат). Компании представляли отчетность в Росстат, и эти данные использовались преимущественно для формирования макроэкономической и отраслевой статистики. В связи с этим бухгалтерская отчетность за более ранние периоды аккумулировалась в статистических информационных системах. В дальнейшем функции по централизованному сбору бухгалтерской отчетности были переданы Федеральной налоговой службе (ФНС России), на базе которой был создан Государственный информационный ресурс бухгалтерской отчетности (ГИР БО). Начиная с

---

<sup>2</sup> <https://iss.moex.com/iss/reference/>

отчетности за 2019 год, финансовая отчетность организаций формируется и хранится в едином электронном ресурсе ФНС. На основе отчетных показателей рассчитываются финансовые коэффициенты, характеризующие ликвидность, финансовую устойчивость, рентабельность и деловую активность компаний.<sup>3</sup> В настоящий момент все данные агрегированы и доступны в виде готового структурированного датасета на платформе Hugging Face.<sup>4</sup> Создание и подготовка этого набора данных были реализованы коллективом исследователей из Европейского университета [3].<sup>5</sup>

Для расширения набора финансовых характеристик и использования агрегированных показателей в анализе дополнительно применяются данные специализированных финансово-аналитических ресурсов, включая платформу Financemarket, предоставляющую расчетные финансовые мультипликаторы на основе отчетности компаний.<sup>6</sup>

Справочная информация о компаниях-эмитентах, а также дополнительные сведения, необходимые для идентификации и сопоставления данных из различных источников, получены из информационных систем «Интерфакс – RuData», а также официальных публикаций Центрального банка Российской Федерации. Данные RuData применяются для сопоставления информации, полученной из различных источников, и формирования единого набора данных для последующего анализа. В частности, сведения о компаниях используются для корректного объединения данных бухгалтерской отчетности, рыночных показателей и финансовых мультипликаторов.<sup>7</sup>

В работе для расширения признакового пространства моделей машинного обучения применяются макроэкономические и банковские показатели, публикуемые Центральным банком Российской Федерации (ЦБ РФ). Эти данные доступны через официальный веб-сервис ЦБ и включают как ключевые ставки и инфляцию, так и курсы валют и металлов, показатели ликвидности и операций на финансовом рынке.<sup>8</sup>

---

<sup>3</sup> <https://bo.nalog.gov.ru/>

<sup>4</sup> <https://huggingface.co/datasets/irlspbru/RFSD>

<sup>5</sup> <https://github.com/irlcode/RFSD>

<sup>6</sup> <https://financemarket.ru/api/>

<sup>7</sup> <https://docs.efir-net.ru/>

<sup>8</sup> <https://www.cbr.ru/DailyInfoWebServ/DailyInfo.aspx>

Совместное использование указанных источников позволяет сформировать комплексный набор данных, включающий бухгалтерскую отчетность, производные финансовые показатели, рыночные оценки и справочную информацию, что обеспечивает возможность построения и анализа моделей машинного обучения для оценки финансового состояния компаний.

#### b. Целевая переменная

В данной работе для оценки финансового состояния компаний в качестве целевой переменной используется дневная рыночная капитализация. Этот показатель определяется так:  $MC_{i,j} = P_{i,j} * N_{i,j}$ , где  $MC$  – рыночная капитализация,  $P$  – рыночная цена обыкновенной акции компании,  $N$  – количество акций в обращении,  $i$  – идентификатор компании,  $j$  – момент времени (в данном случае, на конец дня). Рыночная капитализация учитывает одновременно множество аспектов деятельности компании: прибыльность, устойчивость, перспективы роста и риск. В отличие от отдельных бухгалтерских показателей, она агрегирует оценки инвесторов, отражая текущую и ожидаемую стоимость компании. Дневная капитализация позволяет формировать временные ряды, что дает возможность моделировать динамику финансового состояния и выявлять тренды. Также использование капитализации как целевой переменной позволяет напрямую исследовать связь между внутренними финансовыми показателями компании и рыночной оценкой, что делает модели интерпретируемыми и экономически значимыми.

#### c. Признаки

В рамках данной работы формируется пространство размерности в 270 признаков. Использование такого числа признаков направлено на повышение информативности входных данных и обеспечение применимости современных методов машинного обучения к задаче оценки финансового состояния компаний. Анализ охватывает выборку из 207 компаний, представленных в 11 различных секторах экономики. Отраслевая принадлежность компании включена в число признаков и используется для учета структурных различий в бизнес-моделях, уровне капиталоемкости, рентабельности и финансовых рисках, характерных для отдельных секторов.

Первую и базовую группу признаков составляет финансовая отчетность компаний, содержащая ключевые показатели их хозяйственной деятельности и финансовых

результатов. Она формируется на основе бухгалтерской отчетности по РСБУ и МСФО и охватывает детализированные показатели бухгалтерского баланса, отчета о финансовых результатах и отчета о движении денежных средств. 1 данную группу входят сведения об организации, данные о бухгалтерском балансе, отчет о финансовых результатах, отчет об изменениях капитала, отчет о движении денежных средств, 1 также аудиторское заключение и 4 яснения к бухгалтерскому балансу и отчету о финансовых результатах. 1 составе финансовой отчетности 12 можно выделить несколько укрупненных групп показателей, отражающих различные аспекты финансово-хозяйственной деятельности компании и традиционно используемых в финансовом анализе: 1) показатели ликвидности и платежеспособности формируются преимущественно на основе бухгалтерского баланса и характеризуют способность компании своевременно выполнять краткосрочные обязательства. К данной группе относятся структура оборотных активов, величина денежных средств и их эквивалентов, 1 дебиторская задолженность, краткосрочные обязательства и соотношения между ними; 2) показатели финансовой устойчивости и структуры капитала отражают степень зависимости компании от заемных источников финансирования и устойчивость ее финансовой структуры. Рассчитываются на основе данных о собственном капитале, долгосрочных и краткосрочных обязательствах, резервах и нераспределенной прибыли, представленных в бухгалтерском балансе и отчете об изменениях капитала; 3) показатели рентабельности характеризуют эффективность использования ресурсов компании и способность генерировать прибыль. Формируются на основе отчета о финансовых результатах и включают показатели прибыли на различных уровнях (операционной, до налогообложения, чистой), а также соотношения прибыли с выручкой, активами и капиталом. 4) показатели деловой активности (оборачиваемости) отражают интенсивность использования активов и капитала в процессе хозяйственной деятельности. Основаны на данных о выручке, запасах, дебиторской и кредиторской задолженности и позволяют оценить скорость оборота основных элементов баланса; 5) показатели денежных потоков формируются на основе отчета о движении денежных средств 1 характеризуют способность компании генерировать денежные средства по операционной деятельности, а также направления их использования в инвестиционной и финансовой деятельности. Данная группа дополняет показатели прибыли и позволяет оценить качество финансовых результатов; 6) показатели накопления и распределения

капитала отражаются в отчете об изменениях капитала и характеризуют процессы формирования собственного капитала, выплаты дивидендов, создание резервов и влияние переоценок и корректировок на финансовое положение компании.

Следующая группа признаков представляет собой финансовые коэффициенты и рыночные мультипликаторы, рассчитываемые на основе бухгалтерской отчетности, а также рыночной оценки компании. Вместе эти показатели нужны для того, чтобы привести финансовые данные компаний к сопоставимому виду. Абсолютные значения сами по себе не всегда удобны для сравнения: крупная компания почти всегда будет иметь больше активов, выручки или долга, чем небольшая, но это ещё не означает, что её финансовое положение лучше или хуже. Поэтому в модели используются коэффициенты и мультипликаторы, которые позволяют сравнивать компании разного масштаба, из разных отраслей и с разной структурой капитала. В набор признаков входят инвестиционные мультипликаторы. Они показывают, как рыночная стоимость компании соотносится с её прибылью, выручкой, денежными потоками и другими финансовыми результатами. Такие показатели часто применяются при сравнительной оценке бизнеса: с их помощью можно увидеть, выглядит ли компания относительно дорогой или, наоборот, недооценённой по сравнению с другими эмитентами. Отдельный блок составляют показатели рентабельности. Они отражают, насколько эффективно компания использует активы, собственный капитал и операционные ресурсы. Для анализа это важно, потому что высокая выручка сама по себе ещё не говорит о качестве бизнеса. Компания может много продавать, но получать низкую прибыль. Поэтому рентабельность помогает оценить именно способность бизнеса создавать доходность на вложенные ресурсы. Показатели долговой нагрузки и финансового риска описывают, какую роль в финансировании компании играет заёмный капитал. Они также позволяют оценить, насколько чувствительным может быть финансовое положение компании к росту процентных ставок или снижению операционной прибыли. Если долговая нагрузка высокая, даже небольшое ухудшение выручки или маржинальности может заметно повлиять на устойчивость бизнеса. Показатели ликвидности и оборотного капитала используются для оценки краткосрочной платёжеспособности. Они показывают, хватает ли компании оборотных активов для покрытия текущих обязательств и насколько эффективно она управляет запасами, дебиторской и кредиторской задолженностью. Этот блок дополняет анализ долговой нагрузки, потому что компания может выглядеть устойчивой по

долгосрочным показателям, но при этом иметь проблемы с текущими платежами. Также в набор включены инвестиционные и дивидендные показатели. Они характеризуют, как компания распределяет денежные потоки: направляет средства на развитие, удерживает прибыль внутри бизнеса или выплачивает её акционерам. Для моделей это полезно, так как такая политика может быть связана как с текущим финансовым состоянием, так и с ожиданиями относительно будущего роста. Часть показателей представлена в двух вариантах — по РСБУ и по МСФО. Это важно, поскольку разные стандарты могут по-разному отражать активы, обязательства, прибыль и отдельные операции компании. Использование обеих версий позволяет учесть различия в раскрытии отчётности и получить более полное описание финансового состояния эмитентов.

Отдельную группу признаков составляют макроэкономические и денежно-кредитные показатели, отражающие общее состояние экономики и условия функционирования финансового рынка. В данную группу включены ключевая ставка Банка России и показатели инфляции, которые характеризуют стоимость капитала и уровень макроэкономической стабильности, а также параметры ликвидности банковского сектора и операций Банка России, отражающие объёмы предоставления и изъятия ликвидности. Дополнительно используются показатели инструментов денежного рынка и операций рефинансирования, позволяющие учитывать изменения в механизмах монетарной политики. В качестве внешних макрофинансовых факторов в модель включены цены на драгоценные металлы, валютные курсы, а также показатели денежного рынка RUONIA, характеризующие краткосрочную стоимость рублевой ликвидности. Использование данной группы признаков позволяет учитывать влияние макроэкономической конъюнктуры и финансовых условий на финансовое состояние и рыночную оценку компаний.

Развернутое описание каждого используемого признака вынесено в приложение к выпускной квалификационной работе.

## 2. Обзор литературы

Разделим научную литературу, используемую в данной работе, на три группы. В первой группе рассматриваются исследования, посвящённые применению методов машинного обучения в финансах в целом. Здесь машинное обучение выступает как инструмент для улучшения прогнозирования доходностей, отбора факторов и построения

инвестиционных стратегий в условиях сложных, высокоразмерных и шумных данных. Литература показывает, что ML-подходы способны выявлять нелинейные зависимости, сложные взаимодействия между признаками и структурные изменения на рынке, которые классические линейные модели часто не улавливают. Важным аспектом является также способность машинного обучения работать с большим числом факторов одновременно, снижая необходимость ручного отбора признаков. При этом отдельная подгруппа работ фокусируется на сравнении классических эконометрических методов и современных алгоритмов ML, показывая преимущества последних в предсказательной точности. Однако исследователи подчёркивают, что статистическое улучшение не всегда автоматически приводит к устойчивой экономической прибыли, потому что результаты чувствительны к качеству данных, выбору метрик валидации, рыночным ограничениям и транзакционным издержкам. Современный консенсус смещается от противопоставления методов к их комбинации: машинное обучение используется для извлечения сложного сигнала, а эконометрический аппарат — для интерпретации, проверки устойчивости и экономической обоснованности полученных результатов. Дополнительно отмечается, что интеграция ML с эконометрикой позволяет также выявлять новые финансовые факторы и уточнять существующие модели ценообразования.

В первой группе работ рассматривается применение машинного обучения в финансовом анализе в целом. Общий вывод здесь достаточно понятный: ML-модели часто лучше справляются с теми зависимостями, которые плохо описываются обычными линейными спецификациями. В финансовых данных такие случаи встречаются постоянно. Связь между показателями может быть нелинейной, зависеть от состояния рынка, отрасли, размера компании или сочетания нескольких факторов. Линейная модель в такой ситуации обычно фиксирует только усреднённый эффект, а часть информации просто теряется. Отдельное преимущество ML-подходов связано с работой с большим числом признаков. В классическом анализе исследователь часто заранее выбирает ограниченный набор факторов, потому что модель иначе становится трудно интерпретировать или она начинает работать нестабильно. Алгоритмы машинного обучения позволяют включать в рассмотрение больше переменных и затем уже эмпирически проверять, какие из них действительно дают вклад в прогноз. Это не отменяет содержательный отбор признаков, но



снижает зависимость результата от ручной предварительной спецификации модели. При этом в литературе подчёркивается и важное ограничение. Более высокая точность прогноза сама по себе ещё не означает, что модель будет полезна в реальной финансовой задаче. Результат может зависеть от качества данных, способа разбиения выборки, выбранных метрик, транзакционных издержек и ограничений рынка. Поэтому машинное обучение обычно рассматривается не как замена эконометрики, а как дополнение к ней. ML-модели помогают извлекать сложный сигнал из данных, а эконометрические методы нужны для проверки устойчивости результата, интерпретации факторов и оценки того, имеет ли найденная зависимость экономический смысл. В этом смысле современный подход скорее комбинированный: важна не только точность, но и понимание того, за счёт чего она достигается.<sup>9</sup>

Вторая группа работ связана с ансамблевыми методами и их применением к прогнозированию временных рядов. Ансамбли здесь интересны потому, что они позволяют объединять несколько слабых или нестабильных моделей в более устойчивую конструкцию. На практике это важно: финансовые временные ряды шумные, часто меняют поведение, а

---

<sup>9</sup> Avramov D., Cheng S., Metzker L. Machine Learning versus Economic Restrictions: Evidence from Stock Return Predictability // Working paper. — 2023. — URL: <https://ssrn.com/abstract=4481306>

Coqueret G., Guida T. Machine learning for factor investing: Python version — Boca Raton: CRC Press, 2023. — ISBN 978-1-003-12159-6

Gu S., Kelly B., Xiu D. Empirical asset pricing via machine learning // Journal of Financial Economics. — 2020. — Vol. 138, No. 3. — P. 622–650. — DOI: 10.1016/j.jfineco.2020.07.006 — URL: <https://www.sciencedirect.com/science/article/pii/S0304405X20301813>

Kelly B. T., Xiu D. Financial machine learning // Working paper. — 2023. — URL: [https://bfi.uchicago.edu/wp-content/uploads/2023/07/BFI\\_WP\\_2023-100.pdf](https://bfi.uchicago.edu/wp-content/uploads/2023/07/BFI_WP_2023-100.pdf)

López de Prado M. Advances in financial machine learning — Hoboken: Wiley, 2018. — ISBN 978-1-119-49036-9

Mai J., Zhang S., Zhao H., Pan L. Factor investment or feature selection analysis? // Mathematics. — 2024. — Vol. 13, No. 1: 9 — DOI: 10.3390/math13010009 — URL: <https://www.mdpi.com/2227-7390/13/1/9>

Nagel S. Machine Learning in Asset Pricing / Princeton University Press. — Princeton, NJ: Princeton University Press, 2021. — 160 p. — ISBN 9780691218700 — DOI: 10.23943/princeton/9780691218717 — URL: <https://doi.org/10.23943/princeton/9780691218717>

Shi C. From Econometrics to Machine Learning: Transforming Empirical Asset Pricing // Journal of Economic Surveys. — 2026. — Vol. 40, No. 1. — P. 528–548 — DOI: 10.1111/joes.70002 — URL: <https://ideas.repec.org/a/bla/jecsur/v40y2026i1p528-548.html>

Yuan, P. Multi-factor Selection and Stock Picking Strategy Based on Random Forest and LightGBM Algorithms. — 2025. — Vol. 1, No. 1 (Issue 6). — DOI: 10.61173/w66yzp49. — URL: <https://aaltodoc.aalto.fi/items/543c8893-91a7-4a61-b4c4-ff42f5283a3c>

одна модель может хорошо работать на одном участке данных и заметно хуже — на другом. Композиционные методы частично снижают эту проблему за счёт усреднения, последовательного исправления ошибок или объединения разных источников информации. Для финансовых задач особенно важным стало вероятностное прогнозирование. Точечный прогноз показывает только одно ожидаемое значение, но в реальных решениях часто нужно понимать и разброс возможных исходов. Например, интерес представляет не только ожидаемая доходность или изменение капитализации, но и вероятность сильного отклонения в неблагоприятную сторону. Поэтому в литературе всё больше внимания уделяется моделям, которые строят интервалы, квантили или целое условное распределение целевой переменной. В этом контексте выделяется работа Duan et al., где предложен метод NGBoost. Его идея состоит в том, что градиентный бустинг используется не только для получения точечного прогноза, а для оценки параметров распределения. В результате модель даёт ожидаемое значение, но вместе с ним — оценку неопределённости. Для финансовых данных это полезно, потому что риск редко сводится к одному числу. Часто важнее понять диапазон возможных значений и вероятность плохих сценариев. Ансамблевые методы в целом считаются одними из сильных инструментов прогнозирования, но их качество сильно зависит от постановки эксперимента. Нужно аккуратно выбирать схему валидации, не допускать утечки будущей информации, учитывать вычислительную стоимость и не терять интерпретируемость полностью. В финансовых временных рядах это особенно чувствительно: небольшая ошибка в разбиении данных может дать завышенную оценку качества модели. Отдельно в литературе отмечается развитие инструментов для работы с временными рядами. Например, библиотека `sktime` предлагает единый интерфейс, близкий к `scikit-learn`, и объединяет типовые операции подготовки рядов, построения признаков, обучения моделей и проверки качества прогноза. Для исследовательской работы это важно не только с технической точки зрения. Единый фреймворк снижает риск методических ошибок и упрощает сравнение разных алгоритмов на одних и тех же данных, в том числе на финансовой отчётности и рыночных временных рядах.<sup>10</sup>

---

<sup>10</sup> Davis R. A., Nielsen M. S. Modeling of time series using random forests: Theoretical developments // *The Annals of Statistics*. — 2020. — Vol. 48, No. 4. — P. 2199–2223. — DOI: 10.1214/19-AOS1875 — URL: <https://doi.org/10.1214/19-AOS1875>

Третья группа научной литературы сосредоточена на данных финансовой отчетности как источнике фундаментальной информации о будущих денежных потоках, устойчивости прибыли и риске компании. Показатели отчетности обладают прогностической силой и могут использоваться для оценки ожидаемой рыночной доходности. В настоящем исследовании учитываются работы, отражающие современный этап развития, где традиционные статистические методы дополняются алгоритмами машинного обучения для более точного выявления сигналов о будущем финансовом состоянии компаний. В качестве репрезентативного примера масштабной структурированной базы можно рассматривать Russian Financial Statements Database (Bondarkov et al.), где сформирован гармонизированный массив годовой неконсолидированной отчетности по широкому кругу компаний, включая не только подавших, но и не подавших отчетность. Часто литература ставит задачу прогнозирования банкротства, как в (Cheng et al.), однако подходы к анализу отчетности можно расширять и на прогнозирование будущей переоценки акций или других рыночных событий. Современная отчетность является многослойным источником данных: кроме числовых форм, она включает текстовые раскрытия, содержащие информацию о

---

Bryzgalova S., Pelger M., Zhu J. Forest through the Trees: Building Cross Sections of Stock Returns // *Journal of Finance*. — 2025. — Vol. 80, No. 5. — P. 2447–2506. — DOI: 10.1111/jofi.13477 — URL: <https://onlinelibrary.wiley.com/doi/10.1111/jofi.13477>

Duan T., Avati A., Ding D. Y., Thai K. K., Basu S., Ng A., Schuler A. NGBoost: Natural Gradient Boosting for Probabilistic Prediction // *Proceedings of the 36th International Conference on Machine Learning (ICML 2019)*. — Long Beach, California, USA, 2019. — P. 2690–2700.

Guijo-Rubio D., Middlehurst M., Arcencio G., Furtado Silva D., Bagnall A. Unsupervised feature based algorithms for time series extrinsic regression // *Data Mining and Knowledge Discovery*. — 2023. — Vol. 37, No. 3. — P. 1234–1259. — DOI: 10.1007/s10618-023-00909-5 — URL: <https://link.springer.com/article/10.1007/s10618-023-00909-5>

Löning M., Bagnall A., Ganesh S., Kazakov V., Lines J., Király F. J. sktime: A unified interface for machine learning with time series // *arXiv preprint*. — 2019. — URL: <https://arxiv.org/abs/1909.07872>

Machete, R. L. Contrasting probabilistic scoring rules. // *Journal of Statistical Planning and Inference*, 143(10) - 2013 – p. 1781–1790.

Martens, J. New insights and perspectives on the natural gradient method. // *Technical report*. – 2014. - arXiv: 1412.1193.

Nasios I., Vogklis K. Blending gradient boosted trees and neural networks for point and probabilistic forecasting of hierarchical time series // *arXiv preprint*. — 2023. — DOI: 10.48550/arXiv.2310.13029 — URL: <https://arxiv.org/abs/2310.13029>

Nespoli L., Medici V. Multivariate Boosted Trees and Applications to Forecasting and Control // *Journal of Machine Learning Research*. — 2022. — Vol. 23. — P. 1–35 — URL: <http://jmlr.org/papers/v23/21-0247.html>

Tan C. W., Bergmeir C., Petitjean F., Webb G. I. Time Series Regression. — 2022. — URL: <https://arxiv.org/abs/2201.11945>

качестве корпоративной коммуникации, рисках и ожиданиях менеджмента. Поэтому теоретически обоснованным является объединение структурированных и неструктурированных признаков в едином аналитическом контуре.<sup>11</sup>

## Глава I. Описание методов машинного обучения для анализа финансовой отчетности

Теоретическая основа анализа финансовой отчетности в данной работе строится на представлении отчетности как формализованной информационной модели бизнеса [19; 20; 24; 25]. Она одновременно отражает текущее финансовое состояние компании, динамику ее результатов и ограничения по устойчивости, поэтому может использоваться не только для ретроспективной диагностики, но и для прогнозирования будущих экономических исходов [1; 5]. В рамках этой логики учетные показатели интерпретируются как сигналы будущих денежных потоков, прибыльности и риска [20; 21; 27]. Предиктивная ценность возникает не столько из отдельных коэффициентов, сколько из их совместной структуры: сочетаний, относительных изменений во времени и взаимосвязей между блоками отчетности (ликвидность, рентабельность, долговая нагрузка, оборачиваемость, качество прибыли) [9;

---

<sup>11</sup> Al-Kassar T., Saadat M., Moloi T., Masadeh A., Al-Hattab A., Jrairah T. The use of accounting and financial ratios to predict failure: The case of Jordan // *Academy of Accounting and Financial Studies Journal*. — 2019. — Vol. 23, No. 3. — URL: <https://www.abacademies.org/articles/the-use-of-accounting-and-financial-ratios-to-predict-failure-the-case-of-jordan.pdf>

Bondarkov S., Ledenev V., Skougarevskiy D. Russian financial statements database: A firm-level collection of the universe of financial statements // *Sci. Data*. — 2025. — Vol. 12, Art. 995. — DOI: 10.1038/s41597-025-05150-1 — URL: <https://www.nature.com/articles/s41597-025-05150-1>

Chen T. K., Liao H. H., Chen G. D., Kang W. H., Lin Y. C. Bankruptcy prediction using machine learning models with the text-based communicative value of annual reports // *Expert Syst. Appl.* — 2023. — Vol. 233. — Article 120714. — DOI: 10.1016/j.eswa.2023.120714 — URL: <https://www.sciencedirect.com/science/article/pii/S0957417423012162>

Ou J. A., Penman S. H. Financial statement analysis and the prediction of stock returns // *Journal of Accounting and Economics*. — 1989. — Vol. 11, No. 4. — P. 295–329. — DOI: 10.1016/0165-4101(89)90017-7 — URL: <https://www.sciencedirect.com/science/article/pii/0165410189900177>

Piotroski J. D. Value investing: The use of historical financial statement information to separate winners from losers // *Journal of Accounting Research*. — 2000. — Vol. 38, Suppl. — P. 1–41. — DOI: 10.2307/2672906 — URL: <https://www.jstor.org/stable/2672906>

Волков Д. Л. Управление ценностью: показатели и модели оценки // *Российский журнал менеджмента*. — 2005. — Т. 3, № 4. — С. 67–76

Бухвалов А. В., Волков Д. Л. Фундаментальная ценность собственного капитала: использование в управлении компанией // *Научные доклады*. — No R 1–2005. — СПб.: НИИ менеджмента СПбГУ, 2005

Ивашковская И. В. Модели экономической прибыли и контроль создания стоимости компании: дискуссионные вопросы — 2022. — С. 22

11; 17]. Следовательно, предмет анализа — это система признаков, а не изолированные метрики [6; 15].

Второй ключевой элемент теоретической базы связан с рискованной интерпретацией отчетности. Финансовые показатели выступают прокси-переменными для вероятности неблагоприятных событий (финансовые затруднения, ухудшение кредитного профиля, снижение инвестиционной привлекательности) [1; 5]. Отсюда вытекает методологический переход от описательного финансового анализа к постановке задач регрессии и прогнозирования вероятностей [8; 11].

Третий элемент — стоимостная перспектива. Показатели отчетности рассматриваются как факторы формирования фундаментальной ценности и экономической прибыли [25; 26; 27]. Это позволяет связать бухгалтерские данные с задачами оценки стоимости компании и эффективности управления ценностью, а также корректно обосновать выбор целевых переменных в эмпирических моделях [20; 21].

Переход от эконометрических моделей к методам машинного обучения в финансовом анализе связан не с отказом от теории, а с изменением масштаба и структуры данных. Классическая эконометрика эффективно работает в условиях ограниченного числа факторов и заранее заданной функциональной формы, однако в задачах анализа отчетности и ценообразования активов исследователь все чаще сталкивается с сотнями признаков, сложными взаимодействиями и нестабильными рыночными режимами [11; 22]. Главное ограничение традиционных линейных спецификаций проявляется в высокоразмерной среде: при росте числа признаков усиливаются мультиколлинеарность, чувствительность оценок к выборке и риск переобучения при попытке вручную усложнить модель. Одновременно предпосылка линейности становится слишком жесткой, поскольку реальные зависимости в финансовых данных часто имеют пороговый, асимметричный и нелинейный характер. В результате модели, хорошо интерпретируемые внутри выборки, нередко дают слабый вневыборочный прогноз [11; 17].

Методология машинного обучения предлагает другой исследовательский акцент: от приоритетной проверки параметров фиксированной модели — к систематическому поиску устойчивой прогностической зависимости. Это достигается за счет регуляризации, гибких нелинейных алгоритмов, процедур отбора признаков и строгой вневыборочной валидации.

В такой рамке центральным критерием качества становится не только статистическая значимость коэффициентов, но и воспроизводимая точность прогноза на новых данных [13; 22]. При этом современный подход носит гибридный характер. Экономическая интерпретация, ограничения реализуемости стратегий и контроль за методологическими ошибками сохраняются как обязательные элементы исследования, а ML выступает инструментом повышения адаптивности моделей к сложной структуре финансовой информации. Таким образом, эволюция от эконометрики к машинному обучению представляет собой переход от «жестко специфицированных» моделей к данным-ориентированной, но теоретически осмысленной аналитике [11; 13; 17].

Развитие ML-подходов в финансовом анализе связано с переходом от «классических» ансамблей к более гибким архитектурам, которые одновременно повышают точность, учитывают многомерность целевых переменных и дают оценку неопределенности прогноза. В этой логике бустинг выступает как базовый механизм последовательного улучшения модели, а гибридные и вероятностные конструкции — как его прикладное расширение под специфику финансовых задач [8; 19]. Важное направление здесь — многомерный бустинг. В отличие от стандартной постановки с одной целевой переменной, Multivariate Boosted Trees позволяют совместно моделировать несколько взаимосвязанных выходов и учитывать их кросс-корреляции. Формально для векторной цели ( $y_i \in \mathbb{R}^K$ ) модель имеет вид:

$$y_i = F(x_i) \in \mathbb{R}^K, \quad F_t(x) = F_{t-1}(x) + \eta \cdot h_t(x),$$

а функция потерь учитывает совместную структуру ошибок:

$$L = \sum_{i=1}^n \|y_i - \hat{y}_i\|_{\Sigma}^2 + \Omega(F),$$

где  $\Sigma$  — матрица ковариации между компонентами целевого вектора. Для финансовой аналитики это принципиально, поскольку многие целевые показатели (доходность, риск, компоненты денежных потоков, показатели устойчивости) формируются как взаимозависимая система, и отдельное моделирование может терять существенную информацию о структуре данных [19]. Деревья решений и ансамблевые методы подходят для анализа финансовых данных, поскольку хорошо работают в условиях, типичных для отчетности и рыночных признаков: высокой размерности, нелинейных зависимостей,

пороговых эффектов и сложных взаимодействий факторов. В отличие от жестко заданных линейных спецификаций, такие модели извлекают структуру данных более гибко и при этом сохраняют прикладную интерпретируемость через важности признаков и анализ вкладов отдельных переменных [4; 24]. С практической точки зрения полезно рассматривать ансамбли как семейство взаимодополняющих инструментов. Случайный лес обеспечивает устойчивый базовый прогноз за счет усреднения большого числа деревьев и снижения дисперсии, тогда как бустинговые алгоритмы (в частности LightGBM) последовательно улучшают аппроксимацию, акцентируясь на ранее недообъясненных наблюдениях. Эмпирические результаты для задач отбора акций подтверждают, что комбинация RF и LightGBM позволяет эффективно совмещать классификацию сигналов и регрессионную оценку целевых величин в едином исследовательском контуре, например, через связку  $p_i = P(y_i = 1 | x_i)$ ,  $\hat{r}_i = E[r | x_i]$ ,  $s_i = p_i \hat{r}_i$ , где  $s_i$  используется как итоговый скоринг для ранжирования активов [23].

Отдельное значение в современных задачах анализа данных имеют вероятностные модели, в которых результатом является не точечная оценка, а условное распределение целевой переменной. В этом случае модель задает не одно значение отклика  $y(x)$ , а распределение вида:

$$Y | X=x \sim P_{\theta(x)}, \theta(x) \in R^d,$$

то есть для каждого объекта  $x$  прогнозируется полный вероятностный закон  $P(y | x)$ , на основе которого могут быть получены как ожидаемое значение целевой переменной, так и интервальные оценки, квантили и иные характеристики неопределенности. Такой подход особенно важен в прикладных областях, где необходимо учитывать не только средний ожидаемый эффект, но и вероятность неблагоприятных сценариев. В частности, в финансовых приложениях управленческие решения принимаются не только на основании величины ожидаемой доходности или риска, но и с учетом распределения возможных исходов, включая вероятность экстремальных отклонений. Именно поэтому модели, способные строить калиброванные распределительные прогнозы, представляют особый интерес.

Одним из методов, который подходит для такой постановки, является NGBoost [8]. Его основное отличие от обычных алгоритмов градиентного бустинга состоит в том, что

модель строит не только точечный прогноз. В стандартной регрессии обычно оценивается одно значение — например, условное среднее целевой переменной. Для финансовых данных этого часто мало, поскольку интерес представляет не только ожидаемый результат, но и разброс возможных значений вокруг него. NGBoost решает эту задачу через оценку условного распределения  $P(y | x)$ . То есть для каждого объекта модель подбирает параметры заранее выбранного распределения, а не просто возвращает одно число. В результате можно получить не только прогноз математического ожидания, но и оценку неопределённости. Для задач финансового анализа это важно: при оценке риска необходимо понимать, насколько устойчив прогноз и насколько вероятны неблагоприятные отклонения.

Практическое преимущество NGBoost состоит ещё и в его модульности. В рамках этого подхода можно отдельно выбирать базовый алгоритм, семейство распределений и функцию качества. Поэтому метод достаточно удобно адаптировать под разные типы табличных данных. Библиотека `ngboost` реализует эту идею на практике и позволяет строить вероятностные прогнозы без перехода к более сложным байесовским моделям, которые обычно требуют больших вычислительных затрат. Обучение NGBoost можно записать как задачу минимизации функции потерь, основанной на *proper scoring rule*:

$$L(\theta) = \sum_{i=1}^n \ln S(P_{\theta}(x_i), y_i) .$$

Обучение NGBoost можно записать как задачу минимизации функции потерь, основанной на *proper scoring rule*:

$$S(P_{\theta}(x_i), y_i) = -\log p(y_i | x_i; \theta) .$$

Содержательно это означает следующее. Модель штрафует не просто за ошибку между фактическим и предсказанным значением, как в обычной регрессии. Она оценивается по тому, насколько хорошо построенное распределение объясняет наблюдаемое значение целевой переменной. Поэтому оптимизируется не отдельная точка прогноза, а качество описания всего условного распределения. После обучения модель можно использовать для построения предсказательных интервалов. В общем виде это можно записать так:

$$P(Y \in [q_{\alpha/2}(x), q_{1-\alpha/2}(x)] | X=x) \approx 1-\alpha,$$

где  $q_{\alpha/2}(x)$  и  $q_{1-\alpha/2}(x)$  — соответствующие условные квантили распределения. Такая интервальная оценка полезна в финансовых приложениях, потому что она показывает не



только ожидаемое значение, но и возможный диапазон результата. Именно поэтому вероятностные методы интересны для задач, связанных с риском и нестабильностью финансовых показателей.

Ключевая научная новизна NGBoost состоит в том, что обновление параметров распределения выполняется с использованием натурального градиента. Если условное распределение задается вектором параметров  $\theta$ , то прямое применение обычного градиентного спуска в пространстве параметров приводит к тому, что динамика обучения начинает зависеть от выбранной параметризации распределения. Иными словами, одно и то же распределение, записанное через разные параметры, может порождать различные траектории оптимизации. Кроме того, при совместном обучении нескольких параметров, например среднего и дисперсии, обычный градиент может приводить к несбалансированным обновлениям, когда один параметр изменяется слишком быстро, а другой — слишком медленно. Для устранения этого недостатка в NGBoost используется натуральный градиент, учитывающий геометрию пространства вероятностных распределений:

$$\nabla_{\theta} S(\theta, y) = I(\theta)^{-1} \nabla_{\theta} S(\theta, y),$$

где  $S(\theta, y)$  — выбранная функция качества, а  $I(\theta)$  — риманова метрика статистического многообразия, индуцированная соответствующим scoring rule. В частном случае логарифмического score эта метрика совпадает с матрицей информации Фишера, поэтому шаг натурального градиента принимает вид

$$\nabla_{\theta} L = I(\theta)^{-1} \nabla_{\theta} L.$$

Это означает, что оптимизация осуществляется не просто в евклидовом пространстве параметров, а в геометрии самих распределений, что обеспечивает инвариантность к перепараметризации и более корректную настройку различных компонент параметрического вектора.

Алгоритмически NGBoost сочетает идеи градиентного бустинга и вероятностного моделирования. На каждой итерации вычисляются натуральные псевдоостатки для каждого наблюдения, после чего базовые модели аппроксимируют найденные направления обновления параметров распределения. Далее параметры обновляются по правилу

$$\theta_m(x) = \theta_{m-1}(x) + \eta f_m(x),$$

а в более общем виде с учетом масштабирования шаг может быть записан как

$$\theta_{im} = \theta_{im1} - \eta \rho_m f_m(x_i),$$

где  $\eta$  — скорость обучения,  $\rho_m$  — коэффициент масштаба, определяемый одномерным поиском вдоль направления спуска, а  $f_m(x_i)$  — предсказание базового алгоритма на  $m$ -й итерации. Таким образом, NGBoost поэтапно строит функции, описывающие, как параметры распределения зависят от признаков. Важное отличие от обычного бустинга состоит в том, что аппроксимируется не целевая переменная как таковая, а направления изменения параметров распределения, и именно это делает возможным построение полноценных вероятностных прогнозов.

В модели NBRegressor базовый учитель не предсказывает целевую переменную  $y$  напрямую, а используется для поэтапной аппроксимации направлений спуска в пространстве параметров условного распределения. Поэтому принципиальное различие между моделями Ridge и DescisionTreeRegressor проявляется прежде всего в том, каким классом функций аппроксимируются натуральные псевдоостатки на каждом шаге. **17** не говоря, внешний алгоритм NGBoost в обоих случаях остается одним и тем же — различается именно функциональное пространство, в которое проецируется направление натурального градиента. При использовании линейного учителя для каждого параметра распределения на итерации  $m$  строится линейная функция вида

$$f_{km}(x) = \beta_{0km} + x^T \beta_{km},$$

где коэффициенты определяются из задачи

$$\min_{\beta_{0k}, \beta_k} \sum_{i=1}^n g_{km}(\beta_{0k} + x_i^T \beta_k)^2 + \alpha \|\beta_k\|_2^2.$$

В рассматриваемом случае  $\alpha = 0$ , поэтому регуляризующий член фактически отсутствует, и базовый учитель сводится к обычной линейной least-squares-аппроксимации псевдоостатков. Содержательно это означает, что на каждой итерации NGBoost вносит в каждый параметр распределения глобальную линейную поправку, одинаково заданную на всем пространстве признаков. Для нормального распределения обновление параметров в такой модели можно записать через два уравнения: отдельно для условного среднего и отдельно для логарифма стандартного отклонения. В упрощённом виде это выглядит следующим образом:

$$\mu_m(x) = \mu_{m1}(x) - \eta \rho_m \beta_{0,\mu_m} x^T \beta_{\mu_m}, \quad \log \sigma_m(x) = \log \sigma_{m1}(x) - \eta \rho_m \beta_{0,\sigma_m} x^T \beta_{\sigma_m}.$$

Здесь видно, что на каждом шаге к текущей оценке параметра добавляется линейная функция от признаков. Поскольку сумма линейных функций также остаётся линейной, итоговая зависимость каждого параметра распределения от признаков сохраняет линейный вид:

$$\theta_k(x) = a_k + x^T b_k.$$

Поэтому NGBRegressor с линейным базовым алгоритмом нельзя рассматривать как нелинейный ансамбль в обычном смысле. В такой конфигурации он ближе к распределительной линейной модели, которая обучается пошагово с использованием натурального градиента. Это важное уточнение, потому что сама надстройка NGBoost не делает модель нелинейной, если в качестве базового учителя используется линейная модель.

У такой постановки есть свои преимущества. Она остаётся достаточно интерпретируемой: можно анализировать, как признаки связаны с условным средним и с параметром неопределённости. Кроме того, линейная форма обычно даёт более гладкие зависимости и меньшую дисперсию оценок. Это полезно на данных, где связь между финансовыми признаками и параметрами распределения действительно близка к линейной или хотя бы не содержит резких пороговых эффектов. Но выразительность такой модели ограничена. Без дополнительного конструирования признаков она плохо описывает сложные взаимодействия между переменными, нелинейные пороги и локальные изменения дисперсии. Поэтому линейная версия NGBoost скорее подходит как интерпретируемая базовая конфигурация или контрольная модель, с которой можно сравнивать более гибкие варианты на деревьях решений. Кроме того, при  $\alpha = 0$  регуляризация со стороны самого базового учителя отсутствует, поэтому устойчивость модели достигается главным образом за счёт малого `learning_rate`, `shrinkage` и ранней остановки. При использовании дерева решений базовый учитель для каждого параметра принимает вид кусочно-постоянной функции

$$f_{km}(x) = c_{jkm} \mathbb{1}\{x \in R_{jm}\},$$

где  $R_{jm}$  — области признакового пространства, порожденные последовательностью осевых разбиений, а  $c_{jkm}$  — константа в соответствующем листе дерева. Такое дерево обучается приближать псевдоостатки локально: алгоритм подбирает разбиения так, чтобы уменьшить внутрисегментную квадратичную ошибку по значениям  $g_{ikm}$ . Критерий `friedman_mse`

специально адаптирован к задачам градиентного бустинга и выбирает такие разбиения, которые наиболее эффективно улучшают аппроксимацию направления спуска. При глубине `max_depth=3` каждое дерево остается слабым и формирует лишь ограниченное число локальных областей, однако уже способно моделировать нелинейности и взаимодействия признаков.

В контексте NGBoost это приводит к принципиально иной геометрии обновлений. Если линейный учитель вносит глобальную поправку сразу для всей выборки, то дерево вносит локальные поправки, различающиеся в разных областях пространства признаков. Для нормального распределения это означает, что модель может, например, в одной области признакового пространства увеличивать среднее и одновременно уменьшать неопределенность, а в другой — делать противоположное. После суммирования большого числа неглубоких деревьев модель получает уже не одну простую зависимость, а набор локальных правил для разных областей признакового пространства. Для NGBoost это особенно важно, потому что такие правила строятся не только для условного среднего, но и для параметров распределения. То есть модель может по-разному описывать и ожидаемое значение, и неопределённость прогноза для разных групп наблюдений. Для табличных финансовых данных это часто оказывается полезно. В них нередко встречаются пороговые эффекты: например, умеренная долговая нагрузка может почти не влиять на оценку компании, но после некоторого уровня риск начинает расти гораздо быстрее. Похожая ситуация возможна с ликвидностью, рентабельностью или размером компании. Деревья решений хорошо подходят для таких случаев, потому что они разбивают пространство признаков на участки и позволяют модели работать с ними по-разному. Есть и обратная сторона: деревья дают более гибкую, но менее гладкую зависимость. Оценки могут сильнее меняться от выборки к выборке, особенно если данных немного или в них много шума. Кроме того, деревья плохо экстраполируют за пределы области, которую они видели при обучении. Поэтому такая конфигурация NGBoost может дать выигрыш в точности, но требует более аккуратной настройки и проверки на переобучение.

Сравнение линейного и деревянного регрессора в NGBoost, по сути, сводится к выбору между двумя типами аппроксимации градиентных обновлений. Линейный базовый учитель задаёт глобальную и гладкую зависимость параметров распределения от признаков. Такая модель проще интерпретируется и обычно ведёт себя устойчивее, если связь в данных

действительно близка к линейной. Базовый учитель на деревьях, наоборот, строит локальные кусочно-постоянные обновления. Он лучше подходит для ситуаций, где есть нелинейные эффекты, взаимодействия признаков и неоднородная дисперсия. Поэтому выбор между линейной и деревянной моделями нельзя свести к тому, какая модель «лучше» вообще. Это выбор между интерпретируемостью и гибкостью. Линейная модель уместна как более простая и понятная спецификация, особенно когда нужно проверить базовую линейную гипотезу. Конфигурация с деревьями полезнее там, где предполагается, что условное среднее и неопределённость прогноза меняются по-разному в разных областях данных. В этом смысле NGBoost можно рассматривать как достаточно гибкий инструмент вероятностного прогнозирования. Он объединяет идею градиентного бустинга с оптимизацией параметров распределения через натуральный градиент. Важными свойствами метода являются модульность, возможность выбора распределения и функции качества, а также более сбалансированное обновление параметров по сравнению с обычным градиентным спуском. Для финансовых задач особенно существенно, что NGBoost позволяет учитывать гетероскедастичность, то есть ситуацию, когда разброс целевой переменной меняется в зависимости от признаков. Это делает метод полезным в задачах, где важен не только точечный прогноз, но и оценка неопределённости [8; 14; 16].

Отдельно стоит отметить подход Time Series Forest. Он показывает, что деревья решений можно адаптировать и к временным рядам. Идея состоит в том, чтобы извлекать признаки не из всего ряда сразу, а из отдельных интервалов: например, среднее значение, наклон, дисперсию и другие характеристики на выбранных участках. Затем такие интервальные признаки используются в ансамбле деревьев. Для финансовых временных рядов это важно, потому что полезный сигнал часто содержится не в одном наблюдении, а в форме движения показателя на некотором промежутке времени. Такой подход помогает учитывать динамику данных более корректно, чем простое использование отдельных лагов. Для интервала  $I = [a, b]$  используются статистики вида:

$$\mu_I = \frac{1}{|I|} \int_a^b x_t dt, \quad \sigma_I^2 = \frac{1}{|I|} \int_a^b (x_t - \mu_I)^2 dt, \quad \beta_I = \frac{\int_a^b x_t dt - \mu_I |I|}{\int_a^b (x_t - \mu_I)^2 dt},$$

а итоговый прогноз ансамбля записывается как

$$y = \frac{1}{M} \sum_{m=1}^M T_m z,$$

где  $z$  – вектор интервальных признаков, а  $T_m$  –  $m$ -е дерево. При этом теоретическая состоятельность применения случайных лесов во временном контексте получает строгую

поддержку в рамках нелинейных авторегрессионных процессов, где доказаны свойства сходимости при достаточно общих предпосылках [7]. В задачах факторного прайсинга значение лесов состоит в том, что они позволяют моделировать нелинейные эффекты характеристик и их взаимодействия без предварительно навязанной формы связи:

$$E_{r_{i,t+1}|x_{i,t}} = g(x_{i,t}), \quad g(x) = k_0 + k_1|x| + k_2|x|^2 + \dots$$

Это снижает риск спецификационной ошибки, характерный для линейных факторных моделей, и делает оценку премий за риск более чувствительной к гетерогенности эмитентов и рыночных режимов [4]. Тем самым деревья и ансамбли выступают не только как «технический» инструмент повышения точности, но и как способ уточнения экономической интерпретации факторов.

В задачах анализа финансовой отчетности качество модели в значительной степени определяется не только выбранным алгоритмом, но и тем, как сформировано факторное пространство. Отбор признаков после ансамблевых моделей целесообразно строить не как «разовую» процедуру фильтрации, а как двухуровневый контур: сначала извлекаются структурные временные признаки, затем их значимость агрегируется в экономически интерпретируемые факторные блоки [4]. После обучения модели Time Series Forest на описанных выше интервальных статистиках можно агрегировать важность признаков, которая формально записывается так:

$$\text{Imp}_f = \frac{1}{M} \sum_{m=1}^M \sum_{s \in S_m} \Delta \text{Im}_{f,m,s},$$

где  $\Delta \text{Im}_{f,m,s}$  – уменьшение неопределенности в узле  $s$ . Далее важности раскладываются по горизонту, что дает экономическую интерпретацию важности фактора на определенном лаге. В нашем случае лаг задается в 1 год, так как представлены данные ежегодной отчетности.

Для более глубокой экономической интерпретации результата после обучения ансамблевой модели можно оценить совместно, а не изолированно, вклад факторов путем декомпозиции вклада по временным режимам:

$$r_{i,t+1} = r + \sum_k \phi_k x_{i,t},$$

где  $\phi_k$  – вклад фактора в прогноз. Тогда экономическая интерпретация строится на трех уровнях: 1) важность фактора в ансамбле, 2) знак и нелинейность его предельного эффекта, 3) устойчивость вклада по временным режимам [6]. Практическая реализация данной

интерпретации будет выполнена с помощью информационного коэффициента Пирсона. Для каждого фактора и каждого момента времени он рассчитывается как кросс-секционная корреляция между оцененным вкладом отдельного фактора и последующей реализованной доходностью.

По итогам главы сформирована целостная методологическая рамка анализа финансовой отчетности: от фундаментальной интерпретации бухгалтерских показателей как носителей предиктивных сигналов до выбора прикладных ML-инструментов для задач прогноза. Теоретический контур задан работами по фундаментальному анализу, экономической прибыли и управлению стоимостью, а информационный контур — сочетанием масштабных структурированных баз отчетности и текстовых раскрытий.

В методическом плане показано, что переход от эконометрики к ML обоснован ростом размерности признаков, нелинейностью связей и необходимостью устойчивого качества. В прикладном разрезе наилучший баланс дают ансамблевые и бустинговые подходы: деревья и леса эффективны для нелинейных табличных данных и временной динамики, бустинг и его расширения усиливают качество прогноза в многомерной и вероятностной. Дополнительно устойчивость моделей повышается за счет этапа отбора признаков и факторного дизайна.

Таким образом, практический вывод главы состоит в том, что для **1** анализа финансовой отчетности целесообразно использовать комбинированный пайплайн: экономически осмысленные признаки, отбор и сжатие факторов, вероятностная и объяснимая интерпретация результата с обязательной проверкой вне выборки и учетом прикладных ограничений внедрения.

## Глава II. Программная реализация и экспериментальные результаты

Вычислительный эксперимент данной работы состоит в том, чтобы определить, какие бухгалтерские показатели оказываются наиболее значимыми для прогнозирования динамики капитализации компаний и в какой степени использование бухгалтерской отчетности повышает качество прогноза по сравнению с базовой рыночной постановкой. Для достижения этой цели необходимо <sup>1</sup> подобрать такую конфигурацию модели, которая одновременно дает устойчивое качество на валидации и позволяет интерпретировать вклад отдельных признаков. В рамках исследования проверяются две гипотезы: (1) добавление бухгалтерских факторов к базовому набору признаков приводит к улучшению качества прогноза; (2) модели на основе деревьев решений в среднем демонстрируют более высокую точность по сравнению с линейными моделями.

Состав используемых данных включает три основных блока: рыночные данные, бухгалтерские показатели и служебные признаки. Рыночный блок описывает ежедневное состояние инструмента на рынке и включает показатели капитализации компании, цены закрытия и объема торгов. Дополнительно в этом блоке присутствуют признаки, характеризующие торговый режим и параметры обращения бумаги, в частности идентификаторы режима торгов и сведения о выпуске инструмента. Бухгалтерский блок содержит показатели финансовой отчетности, присоединенные к рыночным наблюдениям. Он включает, с одной стороны, абсолютные значения отчетных статей, отражающих структуру активов, обязательств, капитала, выручки, прибыли и денежных потоков, а с другой стороны — производные финансовые коэффициенты и мультипликаторы. В выборку входят показатели ликвидности, долговой нагрузки, маржинальности, рентабельности, инвестиционной эффективности и рыночной оценки компании. Существенной особенностью набора является наличие показателей как по РСБУ, так и по МСФО, что позволяет учитывать различия в учетных стандартах и расширяет информативность признакового пространства. Служебный блок включает переменные, необходимые для идентификации, упорядочивания и группировки наблюдений. К ним относятся идентификатор инструмента, торговая дата, идентификатор эмитента, наименование бумаги, сектор, тип акции и год наблюдения. Кроме того, в процессе подготовки данных формируются технические признаки, используемые для построения согласованной панели и последующего моделирования, например индикаторы неторговых дней и признаки, связанные с учетом дополнительных выпусков.



На этапе очистки и выравнивания панели данные приводились к единой ежедневной структуре по каждому инструменту. Сначала выполнялась фильтрация наблюдений по допустимым режимам торгов: основной режим, режим вариации расчетов, режимы для низколиквидных и неликвидных бумаг (функция `filter_boards`). После этого обрабатывались случаи, связанные с дополнительными эмиссиями, в результате чего получился признак `issue_cumsum`, представляющий собой флаг допэмиссии (функция `drop_additional_filters`). Далее наблюдения упорядочивались по идентификатору инструмента и торговой дате, после чего устранялись неоднозначности внутри одной даты (функция `set_index`). Следующим шагом для каждого инструмента формировалась полная календарная последовательность дат с дневной частотой. Это было необходимо для приведения всех временных рядов к общей временной сетке и для корректного построения прогноза на фиксированном горизонте (функция `fill_days`). После расширения календаря строился служебный бинарный признак `is_vacation`, представляющий собой флаг отсутствия торгов в указанный день. На заключительном этапе выполнялось заполнение пропусков внутри каждого инструмента. Для этого применялось последовательное прямое (`forward fill`) и обратное (`backward fill`) распространение ближайших доступных наблюдений по времени: сначала пропуски заполнялись последним известным значением, а затем — следующим доступным значением для оставшихся пропусков. Такой подход позволял восстановить непрерывную панель признаков и избежать потери значительной части выборки из-за отсутствующих данных (`ffill_bfill`).

Далее применялись логарифмические изменения с помощью функции `add_log_returns`, реализующей преобразование вида  $rt = \ln P_t P_{t-1}$  отдельно внутри каждого инструмента. Для капитализации формируются признаки логарифмической доходности: `lr_dailycapitalization_1`, представляющий собой логарифмическую доходность за предыдущий день, и `lr_dailycapitalization_30` — логарифмическую доходность с лагом в один месяц. Использование логарифмических доходностей обусловлено их свойствами: они обеспечивают аддитивность во времени, стабилизируют дисперсию временного ряда и позволяют перейти от нестационарного уровня цен (или капитализации) к более стационарному процессу. Это делает их предпочтительными при построении моделей прогнозирования. В рассматриваемой постановке `lr_dailycapitalization_1` выступает в качестве временной целевой переменной, отражающей краткосрочную динамику

капитализации. В обучении будет непосредственно строиться предсказание остатка, а затем восстанавливаться значение целевой переменной капитализации. Признак `lr_dailycapitalization_30` используется как один из объясняющих факторов, поскольку он частично автокоррелирован с целевой переменной и может захватывать более долгосрочные эффекты и инерцию во временном ряду.

Блок финансовых признаков формируется из двух групп переменных: финансовые коэффициенты и мультипликаторы, и абсолютные статьи отчетности. На следующем этапе к признакам применяется сглаживание методом LOWESS (Locally Weighted Scatterplot Smoothing) – методом локального сглаживания ряда. вместо одной глобальной модели на весь ряд в каждой точке строится маленькая локальная регрессия по соседним наблюдениям, в результате чего получается сглаженная кривая, которая повторяет общий тренд и хорошо работает на нелинейных трендах, что свойственно этому типу данных, уменьшает влияние случайных локальных всплесков, делает более устойчивый долгосрочный сигнал, а важность признаков более интерпретируемыми. С другой стороны, чувствителен к выбору параметра `frac`, задающий гладкость итогового временного ряда. В проекте для сглаживания временных рядов используется предопределённая функция LOWESS (Locally Weighted Scatterplot Smoothing) из библиотеки `statsmodels`. Параметр `frac`, определяющий долю наблюдений, используемых при локальной аппроксимации, установлен равным 0.2. Данное значение было выбрано эмпирически: при меньших значениях кривая начинала переобучаться на шум, а при больших — терялись локальные особенности тренда. Визуально `frac=0.2` дало наиболее устойчивый баланс между сглаживанием и сохранением структуры данных. В результате работы функции `lowess_smooth` строятся сглаженные ряды `sm_*`, которые позволяют ослабить влияние локального шума и выделить более устойчивую компоненту динамики бухгалтерских показателей. После сглаживания для сглаженных бухгалтерских признаков дополнительно рассчитываются их однодневные логарифмические изменения. Тем самым модель получает не только уровни бухгалтерских показателей, но и информацию об их краткосрочной динамике. В итоговом признаковом пространстве одновременно присутствуют исходные бухгалтерские признаки, их сглаженные значения и производные `log_returns` для сглаженных рядов, что делает описание финансового состояния компании более насыщенным. На завершающем этапе выполняется преобразование признаков к формату,

пригодному для обучения модели. Категориальные переменные кодируются с помощью OneHotEncoder, а сглаженные числовые признаки масштабируются: признаки с неотрицательной областью значений нормируются через MinMaxScaler, а признаки, принимающие как положительные, так и отрицательные значения, стандартизируются через StandardScaler. После этого формируется итоговая таблица признаков в едином числовом представлении.

В результате формировалась согласованная панель вида «инструмент–дата», пригодная для последующего обучения моделей и проведения валидации по расширяющемуся окну. В прикладной постановке анализируется, как комбинация рыночных и отчетных признаков влияет на точность предсказания целевой переменной в панельной временной структуре. Единицей наблюдения выступает пара «инструмент–дата», то есть запись с индексом  $it$ , где  $i$  — финансовый инструмент (идентификатор  $secid$ ), а  $t$  — торговая дата ( $tradedate$ ). Таким образом, исходный массив имеет панельный формат и может быть представлен как множество наблюдений

$$D = \{ (i, t, X_{i,t}, y_{i,t+1}) \},$$

где  $X_{i,t}$  — вектор признаков, доступных на момент  $t$ , а  $y_{i,t+1}$  — прогнозируемое значение целевой переменной на следующем шаге. Ключом панели является комбинация ( $secid$ ,  $tradedate$ ), что обеспечивает однозначную идентификацию наблюдений и корректную сортировку во времени. Такая структура позволяет одновременно учитывать временную динамику внутри каждого инструмента и межинструментальные различия в едином экспериментальном протоколе. Практически панель является несбалансированной: для разных инструментов длина истории наблюдений может различаться из-за различий в датах листинга, корпоративных событий и неполноты отдельных периодов. Это учитывается в процедуре формирования обучающих и тестовых выборок, где временной порядок сохраняется строго, а качество прогноза оценивается на сопоставимых срезах данных.

Практическая реализация вычислительного эксперимента организована в виде набора Jupyter Notebook, каждый из которых соответствует отдельной конфигурации модели и признакового пространства. Ноутбуки выполняют роль сценариев управления экспериментом: они используют общий программный контур подготовки данных, формирования панели, построения матрицы признаков и вектора отклика, а также единый протокол временной валидации. Благодаря этому различия между отдельными запусками

сводятся не к изменению логики предобработки, а к выбору модели, объема используемого признакового пространства и способа интерпретации результата.

Во всех сценариях эксперимента используется одна и та же общая последовательность действий: сначала загружается предварительно подготовленный набор данных в панельной форме, затем из него выделяются целевая переменная, матрица признаков и базовый уровень капитализации, необходимый для восстановления прогнозов из логарифмической формы. После этого данные передаются в процедуру валидации окна с минимальной длиной обучающего периода в 4 года. На каждом интервале модель обучается на накопленной исторической выборке, после чего строит прогноз для следующего временного интервала. Полученные значения оцениваются по единому набору метрик и логируются в MLflow, что обеспечивает воспроизводимость вычислительного эксперимента и сопоставимость результатов между отдельными конфигурациями. MLflow используется как единая среда фиксации результатов эксперимента: для каждого запуска сохраняются параметры модели, значения метрик качества по отдельным интервалам и их итоговые агрегированные значения. Благодаря пошаговому логированию метрик становится возможным отслеживание динамики качества по мере перехода от одного интервала к другому, а в интерфейсе MLflow эти результаты визуализируются в виде графиков. В качестве артефактов сохраняются обученные модели, что позволяет не только сравнивать конфигурации между собой, но и воспроизводить конкретный запуск, загружать полученную модель для последующего анализа и использовать ее в дальнейших экспериментах. Обучение реализовано в модуле train.py.

Первый сценарий представляет собой базовую конфигурацию вероятностной модели NGBoost без использования расширенного бухгалтерского пространства признаков. В этой постановке в модель подается только сокращенный набор рыночных и служебных признаков, включающий текущую капитализацию, индикатор неторговых дней, признак дополнительной эмиссии и лаговые логарифмические изменения капитализации. В базовой конфигурации используются только рыночные признаки без бухгалтерских факторов. Базовый набор включает 3 признака: 1) лаговый лог-остаток на глубине 30 торговых дней:  $x_{i,t1} = r_{i,t-30}$ ,  $r_{i,t} = \ln C_{i,t} - \ln C_{i,t-1}$ , где  $C_{i,t}$  — капитализация инструмента  $i$  в день  $t$ ; 2) флаг неторгового дня (выходной/праздник): бинарный индикатор, равный 1, если текущая торговая сессия

является первой после разрыва в торгах, и 0 — иначе; 3) значение дополнительной эмиссии `issue_cumsum` - применяется не абсолютный объем дополнительной эмиссии, а накопленный показатель флагов, что имело место это событие на определенном интервале. Данный ноутбук используется для получения опорного качества прогноза в условиях минимального признакового описания. Его основная функция состоит в том, чтобы зафиксировать базовый уровень качества, относительно которого впоследствии можно оценивать прирост от добавления бухгалтерских переменных (`ngboost_base.ipynb`).

Вторая серия запусков реализует основную нелинейную конфигурацию модели NGBoost на полном признаковом пространстве. В этой постановке в модель поступает уже не сокращенный, а полный набор признаков, включающий рыночные переменные, служебные признаки, бухгалтерские коэффициенты, абсолютные статьи отчетности, а также их сглаженные и производные представления. Тем самым данный ноутбук отвечает за проверку ключевой гипотезы исследования: улучшается ли качество прогноза при переходе от базового рыночного описания к расширенному пространству признаков, дополненному бухгалтерской отчетностью. По существу, именно этот сценарий реализует основную эмпирическую проверку вклада финансовой отчетности в задачу прогнозирования (`ngboost_main.ipynb`).

Третий ноутбук реализует альтернативную конфигурацию той же вероятностной схемы NGBoost, но с линейным базовым алгоритмом Ridge вместо дерева решений. Содержательно этот запуск особенно важен, поскольку он позволяет провести контролируемое сравнение двух вариантов одной и той же надстройки NGBoost: нелинейной версии с деревьями и линейной версии с Ridge. Такое сопоставление дает возможность отделить эффект расширенного признакового пространства от эффекта самой архитектуры базового алгоритма. Если «деревянная» конфигурация показывает преимущество над Ridge-конфигурацией при прочих равных условиях, это служит аргументом в пользу того, что связь между целевой переменной и признаками действительно имеет нелинейный характер и не исчерпывается линейной аппроксимацией (`ngboost_ridge.ipynb`).

Для обеспечения воспроизводимости вычислительного эксперимента во всех сравниваемых запусках использовался единый протокол обучения и оценки качества. Все модели обучались на одной и той же предварительно подготовленной панельной выборке,

построенной по общей схеме предобработки, формирования признаков и выделения целевой переменной. Следовательно, различия в качестве прогноза между ноутбуками можно интерпретировать как результат изменения модельной конфигурации и признакового пространства, а не как следствие различий в методике валидации или в структуре обучающей выборки. С методологической точки зрения совокупность этих ноутбуков образует последовательную матрицу экспериментальных сценариев. Базовый запуск задает нижнюю опорную точку качества без бухгалтерских факторов. Полный нелинейный запуск показывает, что происходит при добавлении расширенного бухгалтерского пространства. Линейная конфигурация NGBoost позволяет проверить, насколько значима роль нелинейности внутри одной и той же вероятностной схемы. Наконец, простая линейная регрессия служит внешним ориентиром, позволяющим оценить, насколько использование бустинговой вероятностной модели превосходит более простые линейные подходы. Именно в таком сопоставлении ноутбуки образуют не набор разрозненных технических файлов, а целостную экспериментальную систему, предназначенную для выбора рабочей конфигурации и для последующего анализа вклада бухгалтерской отчетности в предсказание капитализации.

Оценка качества прогнозирования проводится по трем взаимодополняющим метрикам: WMAPE, F1 и IC. Использование именно этого набора позволяет оценить модель с трех разных точек зрения: по точности восстановления исходного уровня капитализации, по способности правильно определять направление изменения доходности и по степени согласованности между предсказанными и фактическими доходностями.

Метрика WMAPE (Weighted Mean Absolute Percentage Error) используется для оценки ошибки прогноза в исходном масштабе капитализации компаний. Поскольку модель строит прогноз в пространстве логарифмических доходностей, итоговые предсказания преобразуются обратно в уровень капитализации, после чего рассчитывается относительная ошибка:

$$WMAPE = \frac{1}{n} \sum_{i,t} \frac{|C_{i,t} - \hat{C}_{i,t}|}{|C_{i,t}|},$$

где  $C_{i,t}$  — фактическая капитализация компании  $i$  в момент времени  $t$ , а  $\hat{C}_{i,t}$  — соответствующее прогнозное значение. Чем меньше значение WMAPE, тем выше точность модели. В отличие от обычной средней процентной ошибки, данная метрика учитывает масштаб наблюдений и потому особенно удобна для панельных данных, в которых

компаний существенно различаются по размеру капитализации. Оценка метрики WMAPE реализована функцией `wmape_score`.

Метрика F1 применяется для оценки качества классификации направления логарифмической доходности. В данной постановке важен не только размер ошибки прогноза, но и способность модели правильно определять знак будущего изменения — положительный или отрицательный. Для этого фактические и прогнозные логарифмические доходности переводятся в бинарную форму:

$$y_{i,t,dir} = 1 \text{ ( } r_{i,t} > 0 \text{)}, y_{i,t,dir} = 1 \text{ ( } r_{i,t} > 0 \text{)},$$

где  $r_{i,t}$  — фактическая логарифмическая доходность,  $\hat{r}_{i,t}$  — прогнозная. После этого рассчитывается F1-метрика:

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}.$$

Таким образом, F1 характеризует, насколько хорошо модель распознает периоды роста и снижения капитализации. Чем выше значение F1, тем лучше модель справляется с определением направления движения. В работе эта метрика считается с помощью функции `f1_score`. Третья метрика — IC, или Information Coefficient. В финансовом моделировании её часто используют для проверки связи между прогнозными и фактическими доходностями. В данной работе IC рассчитывается как корреляция между предсказанной и реализованной логарифмической доходностью  $IC = \text{corr} ( r_{i,t} , \hat{r}_{i,t} )$ . В программной реализации используется коэффициент корреляции Пирсона. Смысл этой метрики достаточно практический: она показывает, насколько прогноз модели согласован с фактическим изменением доходностей. Если IC положительный и остаётся достаточно устойчивым на разных интервалах, это означает, что модель не просто угадывает знак изменения, но и в целом правильно передаёт относительную динамику: какие наблюдения должны иметь более высокую доходность, а какие — более низкую. При этом IC не стоит воспринимать как полную оценку качества модели. Он не показывает размер ошибки в исходных единицах и не заменяет метрики точности прогноза. Его роль другая — проверить, есть ли в прогнозах полезный ранжирующий сигнал. В данной работе значение IC рассчитывается функцией `ic_score`.

Совместное использование WMAPE, F1 и IC позволяет получить более полную картину качества модели. WMAPE оценивает ошибку в исходном масштабе капитализации, F1 — правильность определения знака будущей доходности, а IC — степень

согласованности между прогнозируемыми и фактическими доходностями. Тем самым качество прогноза рассматривается одновременно с точки зрения точности уровней, направлений и общей финансовой информативности предсказания.

Для оценки качества прогнозирования в работе используется схема валидации с расширяющимся окном. В данной постановке на каждом шаге обучающая выборка последовательно увеличивается, тогда как тестирование выполняется на следующем временном интервале, не использованном при обучении. Такой подход позволяет имитировать реальный режим прогнозирования, в котором модель в каждый момент времени опирается только на накопленную историческую информацию и не использует сведения из будущего. Пусть панель наблюдений задана множеством пар «инструмент–дата»  $(i, t)$ , где  $i$  — финансовый инструмент, а  $t$  — торговая дата. Тогда на  $k$ -м шаге валидации обучающая и тестовая выборки можно представить следующим образом:

$$D_{traink} = \{(i, t) : t \leq T_k\}, \quad D_{testk} = \{(i, t) : T_k < t \leq T_k + N\},$$

где  $T_k$  обозначает последнюю дату обучающего окна, а  $N$  — горизонт прогноза. После завершения очередного интервала граница обучающего окна сдвигается вперед, и наблюдения предыдущего тестового периода включаются в обучающую выборку следующего шага. Разбиение выполняется глобально по времени для всей панели сразу, поэтому все инструменты на каждом интервале обучаются и тестируются на одинаковых временных интервалах. Благодаря этому сохраняется сопоставимость результатов между различными моделями и конфигурациями признаков, а различия в метриках качества можно интерпретировать как следствие свойств модели и признакового пространства, а не как результат различий в схеме валидации. Использование схемы расширяющегося окна особенно важно в задачах финансового прогнозирования, поскольку она учитывает временную упорядоченность данных и позволяет избежать утечки информации из будущего. Тем самым обеспечивается корректность как статистической оценки качества, так и экономической интерпретации полученных результатов.

В текущей экспериментальной постановке начальное обучающее окно включает 4 полных года наблюдений. После этого на каждом интервале модель тестируется на следующем календарном году. Таким образом, горизонт прогноза составляет один год, а шаг расширения окна также равен одному году. Следовательно, каждая последующая обучающая выборка содержит всю информацию предыдущего шага и дополнительно



включает еще один год наблюдений. Такая организация обеспечивает два преимущества. Во-первых, по мере продвижения во времени модель обучается на все более полном массиве исторических данных, что повышает устойчивость оценки параметров. Во-вторых, тестирование на каждом шаге осуществляется на одинаковом по длительности интервале, что делает значения метрик качества сопоставимыми между интервалами. Выбор годового горизонта прогноза и годового шага расширения окна согласуется с особенностями используемых данных. Рыночные переменные наблюдаются ежедневно, однако бухгалтерские показатели обновляются существенно реже и несут скорее среднесрочный, чем внутрисуточный сигнал. Поэтому годовой тестовый интервал позволяет корректно оценить вклад бухгалтерской отчетности в прогноз и при этом сохранить реалистичную временную структуру эксперимента. Механизм расширяющегося окна реализован в модуле cv.py.

Для интерпретации результатов в работе отдельно анализируется вклад признаков в прогноз в рамках выбранной tree-конфигурации NGBoostRegressor. Такой анализ позволяет перейти от оценки общего качества модели к содержательному выводу о том, какие именно переменные формируют предсказание и в какой степени бухгалтерская отчетность действительно участвует в объяснении динамики целевой переменной. Поскольку в данной конфигурации в качестве базового алгоритма используются деревья решений, после обучения модели становится возможным извлечение показателей feature importance. Эти значения интерпретируются как количественная мера вклада отдельного признака в снижение ошибки модели при построении ансамбля. Для повышения устойчивости вывода важности признаков анализируются не по одному запуску, а агрегируются по всем интервалам расширяющегося окна. Тем самым оценивается не случайный вклад признака на отдельном временном интервале, а его устойчивая роль в прогнозировании на всей выборке.

Формально для каждого признака  $x_j$  можно ввести усредненную важность

$$F_{Ij} = \frac{1}{K} \sum_{k=1}^K I_{jk},$$

где  $F_{Ijk}$  — важность признака  $x_j$  на  $k$ -м интервале, а  $K$  — число интервалов в схеме расширяющегося окна. При необходимости важности дополнительно нормируются так, чтобы их сумма по всем признакам была равна единице:

$$F_{Ij} = \frac{F_{Ijm}}{\sum_{m=1}^p F_{Ijm}},$$

где  $p$  — число признаков в модели. Такая нормировка делает результаты более наглядными и позволяет интерпретировать их как относительный вклад отдельных переменных.

В прикладном анализе признаки целесообразно рассматривать не только по отдельности, но и по смысловым группам. В рамках данной работы выделяются три блока: рыночные признаки, служебные признаки и бухгалтерские признаки. К первому блоку относятся лаговые логарифмические изменения капитализации, ко второму — признаки календарной структуры и дополнительной эмиссии, к третьему — показатели бухгалтерской отчетности и их сглаженные производные. Это позволяет оценить не только лидирующие отдельные переменные, но и общий вклад каждого информационного блока в формирование прогноза. По результатам интерпретации доминирующими, как правило, оказываются признаки, описывающие недавнюю динамику рыночной капитализации, поскольку именно они непосредственно связаны с краткосрочным движением целевой переменной. В первую очередь к таким переменным относится лаговый логарифмический остаток капитализации, отражающий инерционность временного ряда.

Для содержательной интерпретации результатов в работе целесообразно анализировать не только абсолютные значения важностей, но и структуру лидирующих признаков. Если верхние позиции занимают исключительно рыночные переменные, то вклад бухгалтерской отчетности в прогноз ограничен. Если же среди доминирующих признаков заметную долю составляют бухгалтерские показатели, это означает, что модель действительно использует фундаментальную информацию при формировании прогноза. В таком случае можно перейти от общего утверждения о полезности бухгалтерской отчетности к более конкретному выводу о том, какие именно аспекты финансового состояния компании оказываются наиболее значимыми: ликвидность, долговая нагрузка, рентабельность, инвестиционная активность или структура капитала.

Дополнительно интерпретация может быть проведена на уровне укрупненных групп признаков. Для этого суммарная важность признаков внутри каждой содержательной группы агрегируется:

$$F_{IG} = \sum_{j \in G} F_{Ij},$$

где  $G$  обозначает группу признаков, например рыночные, служебные или бухгалтерские переменные. Такой подход позволяет оценить, какой именно блок данных дает основной вклад в прогноз. Если суммарная важность бухгалтерских признаков оказывается заметной,

это можно рассматривать как аргумент в пользу использования финансовой отчётности в модели. В таком случае отчётность влияет не только на численное качество прогноза, но и на содержательную интерпретацию результата: становится видно, какие группы финансовых показателей модель использует при построении прогноза.

Помимо встроенных оценок feature importance, в работе применяется метод permutation feature importance. Он нужен для дополнительной проверки выводов, полученных по структуре бустинга деревьев. Обычная важность признаков в таких моделях рассчитывается внутри ансамбля: признак считается важным, если он часто используется в разбиениях и даёт заметное снижение функции потерь. Это полезная оценка, но она не всегда показывает, насколько признак действительно влияет на качество прогноза на новых данных. Подход перестановок устроен иначе: после обучения модели берётся тестовая или валидационная выборка. Затем для каждого признака  $x_j$  его значения случайно перемешиваются между наблюдениями, а остальные признаки остаются без изменений. Тем самым информация, содержащаяся именно в этом признаке, разрушается, но общая структура выборки сохраняется. После этого качество модели считается заново. Если после такой перестановки метрика заметно ухудшается, значит, признак **18** твительно был важен для прогноза. Если качество почти не изменилось, то вклад признака, скорее всего, ограничен. Это удобная проверка, потому что она связывает важность признака не с внутренним устройством модели, а с фактической потерей качества. Формально permutation-важность признака  $x_j$  можно записать как среднее снижение качества после нескольких случайных перестановок:

$$P_{Ij} = S(f, X, y) - \frac{1}{R} \sum_{r=1}^R S(f, \pi_{jr}(X), y),$$

где  $S(f, X, y)$  — значение выбранной метрики качества для модели  $f$  на исходных данных,  $\pi_{jr}(X)$  — матрица признаков после  $r$ -й случайной перестановки значений  $j$ -го признака, а  $R$  — число повторов перестановки. Чем выше значение  $P_{Ij}$ , тем сильнее падает качество модели при разрушении информации в данном признаке.

В данной работе permutation-важность используется как дополнение к стандартной feature importance. Это позволяет сравнить две оценки вклада признаков: внутреннюю, основанную на структуре ансамбля, и внешнюю, основанную на изменении качества прогноза. Для бухгалтерских факторов такая проверка особенно полезна. Признак может

часто использоваться деревьями, но при этом почти не улучшать качество на вневыборочных данных. Возможна и обратная ситуация, когда признак используется не так часто, но его перестановка заметно ухудшает прогноз. Если бухгалтерский показатель одновременно имеет высокую встроенную важность и высокую permutation-важность, его можно считать более надёжным кандидатом на содержательную интерпретацию. Если же признак важен только по одной из двух оценок, выводы по нему лучше делать осторожно. Расчёт важности признаков и построение визуализаций реализованы в модуле `features.py`.

### Экспериментальные результаты и вывод

В качестве базовой точки отсчета были сопоставлены две конфигурации модели `NGBoostRegressor` на сокращенном наборе рыночных и служебных признаков без использования бухгалтерской отчетности. Цель этого этапа состояла в том, чтобы отделить вклад самой архитектуры модели от вклада расширенного признакового пространства и определить, какая конфигурация лучше справляется с прогнозированием в минимальной постановке задачи. Результаты показали, что конфигурация с базовым алгоритмом на деревьях решений заметно превосходит линейную конфигурацию. Преимущество модели бустинга деревьев наблюдается по всем основным метрикам качества и носит устойчивый характер по интервалам. Это позволяет сделать вывод о том, что <sup>1</sup> же в базовой постановке зависимость между признаками и целевой переменной имеет выраженный нелинейный характер, который не может быть в полной мере уловлен линейной моделью. Иными словами, уже на минимальном наборе признаков использование деревьев решений внутри `NGBoost` дает существенный выигрыш по сравнению с линейной спецификацией.

Анализ результатов для базовой конфигурации показывает, что наибольший вклад в прогноз по-прежнему вносит лаговый рыночный признак, описывающий предшествующую динамику капитализации. Такой результат является ожидаемым, поскольку именно данный фактор наиболее близок к целевой переменной и отражает инерционность временного ряда. Сравнение модельных конфигураций при этом подтверждает преимущество нелинейной модели над линейной, что свидетельствует о наличии в данных нелинейных зависимостей и взаимодействий между признаками.

Если оставить в стороне чисто рыночные и служебные переменные, то среди бухгалтерских факторов прежде всего выделяются признаки, характеризующие рыночную оценку компании относительно фундаментальной базы, в частности мультипликаторы `P/CF`

по МСФО, P/BV по МСФО и P/FCF по РСБУ. Экономический смысл данной группы состоит в том, что она <sup>1</sup> отражает соотношение между рыночной стоимостью компании и ее способностью генерировать денежный поток, свободный денежный поток и накапливать собственный капитал. Тем самым модель улавливает не только сам уровень капитализации, но и то, каким образом рынок оценивает денежную и балансовую основу бизнеса. Это позволяет говорить о присутствии в сигнале устойчивой фундаментальной компоненты, связанной с относительной оценкой компании.

Существенную роль играют и показатели рентабельности, прежде всего ROA по МСФО, ROCE и ROE по РСБУ, а также валовая и операционная рентабельность по МСФО. Эти переменные характеризуют эффективность использования активов, собственного капитала и долгосрочно задействованных ресурсов, то есть внутреннее качество хозяйственной деятельности компании. Их значимость указывает на то, что модель учитывает не только внешнюю рыночную оценку фирмы, но и ее способность устойчиво создавать прибыль на имеющейся ресурсной базе. Хотя влияние каждого отдельного признака данной группы не является доминирующим, их присутствие среди значимых переменных делает интерпретацию прогноза существенно более содержательной.

Отдельно стоит выделить признаки, связанные с долговой нагрузкой и финансовой устойчивостью. Среди них — Debt Ratio по МСФО, Debt/Equity по РСБУ и показатель покрытия процентных расходов по МСФО. Эти переменные показывают, за счёт каких источников финансируется компания, насколько она зависит от заёмного капитала и может ли обслуживать долг за счёт операционных результатов. Для модели это важно: она учитывает не только возможную доходность бизнеса, но и ограничения, связанные с финансовым риском. Компания может быть прибыльной, но при высокой долговой нагрузке её устойчивость всё равно будет ниже.

Значимыми оказались и показатели, связанные с собственным капиталом. <sup>19</sup> им относятся совокупный финансовый результат периода, резервный капитал, историческая величина капитала, увеличение капитала в предыдущем периоде, а также переоценка внеоборотных активов. Эти признаки описывают не только текущий результат, но и то, как формировалась капитальная база компании. Проще говоря, модель реагирует не только на прибыль за один период, но и на накопленную способность компании поддерживать

устойчивый баланс. Для финансового анализа это содержательно важно, потому что устойчивость бизнеса редко определяется одним отчётным годом.

Дополнительный вклад дают признаки, связанные с ликвидностью и инвестиционной политикой. Сюда относятся финансовые вложения, сальдо денежных потоков от инвестиционных операций, операции по приобретению долговых ценных бумаг и предоставлению займов. Эти переменные показывают, как компания распоряжается денежными ресурсами: удерживает ликвидность, направляет средства в инвестиции, размещает их в финансовые инструменты или предоставляет займы. В таком виде модель учитывает не только прибыльность и структуру капитала, но и реальные решения по использованию денежных средств.

При этом важно отметить ограничение полученных результатов. В полном наборе признаков бухгалтерские переменные в среднем уступают лаговому рыночному фактору. Это ожидаемо: рыночная динамика часто несёт более сильный краткосрочный сигнал. Кроме того, часть бухгалтерских importance-оценок оказывается менее устойчивой. Но для отобранного подмножества признаков разброс значимости ниже. Это говорит о том, что 1 некоторые бухгалтерские показатели всё же дают относительно стабильный вклад и могут рассматриваться как носители фундаментальной информации.

Таким образом, в данной задаче бухгалтерские признаки не формируют главный прогнозный сигнал. Простое расширение признакового пространства за счёт отчётности не приводит к резкому улучшению качества модели. Однако это не означает, что 1 кие признаки бесполезны. Их включение не ухудшает предсказательную силу модели, а по отдельным показателям появляется содержательная экономическая интерпретация. В этом смысле бухгалтерская отчётность выступает не заменой рыночной динамики, а её фундаментальным дополнением: она помогает понять, какие финансовые характеристики стоят за частью прогнозного сигнала. С практической точки зрения следующий шаг достаточно очевиден. Поскольку нелинейная конфигурация показала лучшее качество, но большинство признаков вне лидирующего лагового фактора дают слабый и шумный вклад, имеет смысл перейти к более компактному набору переменных. В работе для этого формируется сокращённое пространство из 20 наиболее значимых признаков, после чего модель повторно обучается уже на этом отобранном наборе. Такой подход должен

одновременно повысить интерпретируемость модели и проверить, удастся ли сохранить или улучшить качество прогноза при уменьшении размерности признакового пространства.

Полученные результаты показывают, что ключевым фактором качества прогноза в рассматриваемой задаче является не столько само расширение признакового пространства, сколько выбор модельной конфигурации. Наиболее устойчивый эффект связан с переходом от линейной базы к «деревянной»-конфигурации NGBoostRegressor: именно это изменение дает основной прирост качества. Напротив, добавление бухгалтерских признаков оказывает существенно более умеренное воздействие: в среднем оно приводит лишь к небольшому улучшению метрик либо практически не меняет результат по сравнению с базовой постановкой. Преимущество tree-конфигурации над линейной версией естественно интерпретируется через различие в выразительной способности моделей. Линейная база предполагает, что вклад каждого признака в прогноз является аддитивным и постоянным по всей выборке. Однако в панельных финансовых данных такая предпосылка часто оказывается слишком жесткой. Влияние признаков может зависеть от уровня капитализации, режима торгов, корпоративных событий, сочетания нескольких факторов и текущего состояния рынка. Деревья решений, напротив, позволяют учитывать пороговые эффекты, локальные нелинейности и взаимодействия между переменными, что делает их более адекватными для описания неоднородной структуры финансовых рядов. Дополнительным источником преимущества конфигурации с деревьями решений является высокая коррелированность признакового пространства. Бухгалтерские коэффициенты, сглаженные показатели и их производные часто содержат частично дублирующуюся информацию. В таких условиях линейная модель склонна распределять вклад между большим числом связанных переменных, что делает оценку менее устойчивой и снижает интерпретируемость. Деревья решений более гибко отбирают информативные разбиения и тем самым лучше работают в условиях высокой размерности и мультиколлинеарности. Наконец, важную роль играет сам характер задачи. Целевая переменная отражает краткосрочную динамику капитализации, в которой присутствуют инерция, асимметрия и режимные переходы. Для такой постановки линейная база оказывается недостаточной, тогда как нелинейная конфигурация лучше извлекает сигнал из сочетания рыночных и служебных признаков. Поэтому более высокое качество нелинейной модели является не

случайным результатом отдельного запуска, а содержательным следствием свойств данных и структуры целевой переменной.

С экономической точки зрения ограниченный эффект бухгалтерских признаков выглядит вполне объяснимым. Целевая переменная в работе характеризует краткосрочную динамику капитализации, тогда как бухгалтерская отчетность по своей природе отражает более медленно меняющееся фундаментальное состояние компании. Между моментом формирования отчетного показателя и его влиянием на рыночную капитализацию существует временной лаг, а сам рыночный отклик на фундаментальную информацию может быть растянут во времени и частично перекрываться иными факторами — ожиданиями инвесторов, новостным фоном, ликвидностью и общим режимом рынка. По этой причине в краткосрочном горизонте доминирующим источником сигнала остаются рыночные лаги, а бухгалтерские данные в среднем дают лишь ограниченное дополнительное уточнение. В то же время отсутствие <sup>1</sup>льного среднего эффекта не означает бесполезности бухгалтерской отчетности. Скорее полученные результаты показывают, что вклад бухгалтерской отчетности распределён между большим числом признаков. Отдельная переменная редко даёт сильный самостоятельный эффект. Но в совокупности такие показатели всё же добавляют информацию к рыночным данным. Если признаки ликвидности, долговой нагрузки, рентабельности или рыночные мультипликаторы регулярно попадают в число значимых, это говорит о наличии фундаментального сигнала. Он не является главным по силе, но полностью игнорировать его тоже нельзя. Поэтому бухгалтерская отчетность в данной задаче не заменяет рыночную динамику. Лаговые рыночные признаки остаются основным источником прогностической информации. Однако отчетность может уточнять прогноз, особенно в тех случаях, когда <sup>1</sup> финансовое состояние компании начинает отличаться от уже сложившейся рыночной траектории. На практике это означает, что <sup>1</sup>хгалтерские признаки работают скорее как дополнительный слой информации: они не всегда резко улучшают метрики, но помогают лучше объяснить, почему модель даёт тот или иной прогноз.

При интерпретации этих результатов нужно учитывать несколько ограничений. Прежде всего, эффективный объём выборки меньше исходного массива данных. Это связано с фильтрацией панели, удалением неполных наблюдений и требованиями к длине исторического ряда для валидации. Такая обработка делает данные более сопоставимыми и



снижает риск методических ошибок, но одновременно уменьшает число компаний и периодов, которые реально используются в экспериментах. Из-за этого выводы по отдельным признакам могут быть менее устойчивыми. Ещё одно ограничение связано с качеством бухгалтерских данных. Отчётность может содержать пропуски, пересмотры, различия в стандартах раскрытия и особенности учётной политики отдельных компаний. Даже если данные формально приведены к единому виду, часть различий между компаниями может быть связана не с экономическим состоянием, а с тем, как именно показатели отражены в отчётности. Поэтому результаты по бухгалтерским признакам следует рассматривать аккуратно: они дают полезную информацию, но требуют содержательной проверки и не должны интерпретироваться механически.

Финансовая отчетность публикуется с временным лагом, может содержать пропуски, пересмотры и неоднородности, связанные с различиями между РСБУ и МСФО. Даже при корректной технической синхронизации такие признаки не всегда полностью отражают ту информацию, которой реально располагал рынок в конкретный момент времени. Поэтому оценка вклада бухгалтерских факторов неизбежно чувствительна к способу привязки отчетности ко временной шкале рыночных наблюдений. В-третьих, дополнительным ограничением является шум в оценках интерпретации. Метрики IC и permutation feature importance показывают, что за пределами нескольких лидирующих признаков ранжирование факторов остается нестабильным по интервалам. Это означает, что при большом числе переменных модель сталкивается с проблемой распыления сигнала. Именно поэтому логичным следующим шагом является отбор ограниченного числа наиболее сильных признаков и повторное обучение модели на сокращенном признаковом пространстве. Такой подход должен позволить одновременно повысить интерпретируемость результатов и проверить, удастся ли сохранить достигнутый уровень качества при меньшей размерности данных.

## Заключение

Выполненное исследование посвящено применению методов машинного обучения для оценки финансового состояния компаний на основе данных финансовой отчетности, рыночных показателей и сопутствующих макроэкономических факторов. Актуальность данной темы определяется тем, что в современных условиях объем доступной корпоративной информации постоянно растет, а задачи анализа финансового положения организаций все чаще выходят за рамки классических коэффициентных подходов и требуют использования более гибких инструментов обработки данных. Традиционные методы финансового анализа по-прежнему сохраняют свою методологическую значимость, однако в условиях высокой размерности признакового пространства, сложных нелинейных

зависимостей и неоднородности временных рядов они нередко оказываются недостаточными для построения устойчивого вневыборочного прогноза. Именно поэтому обращение к методам машинного обучения в данной работе рассматривалось не как отказ от экономической интерпретации, а как естественное развитие инструментов анализа финансовой отчетности.

В ходе работы были последовательно решены поставленные исследовательские задачи. Сначала был проведен обзор теоретических подходов к анализу финансовой отчетности и современной литературы по применению машинного обучения в финансовых задачах. Это позволило показать, что переход от жестко заданных линейных моделей к более гибким ML-подходам обусловлен не модой на алгоритмы, а объективными свойствами самих данных. Финансовое состояние компании, отражаемое в отчетности, формируется под воздействием множества взаимосвязанных факторов, а рыночная реакция на фундаментальные показатели носит сложный, нелинейный и нередко асимметричный характер. В этой связи использование ансамблевых и вероятностных моделей представляется обоснованным и методически оправданным.

Далее была сформирована эмпирическая база исследования. В работе использовалось расширенное признаковое пространство, включающее бухгалтерские показатели компаний, рыночные признаки, служебные переменные, а также макроэкономические и банковские индикаторы. Такая постановка позволила перейти от узкого анализа отдельных коэффициентов к более полной многомерной характеристике состояния компании и условий ее функционирования. При этом в качестве целевой переменной была выбрана краткосрочная динамика капитализации, что задало прикладной фокус исследования: оценить, насколько данные финансовой отчетности способны улучшить прогноз рыночного поведения компании в сочетании с более оперативной рыночной информацией. Важно отметить, что сама постановка задачи уже соответствует современной логике финансового анализа. Фундаментальные и рыночные данные здесь не рассматриваются отдельно друг от друга. Скорее они используются как два разных источника информации о компании. Рыночные признаки быстрее реагируют на новую информацию и настроение участников рынка. Бухгалтерская отчетность, наоборот, отражает более устойчивые характеристики бизнеса: структуру активов, долговую нагрузку,

прибыльность, денежные потоки. Поэтому в прогнозной задаче эти два блока данных логично рассматривать совместно.

Содержательная часть работы была связана с описанием и сравнением методов машинного обучения, которые подходят для такой задачи. Основное внимание уделялось NGBoost, поскольку этот метод позволяет строить не только точечный прогноз, но и оценку неопределённости. Для финансовых приложений это важный момент. На практике редко бывает достаточно одного ожидаемого значения: нужно понимать, насколько прогноз устойчив, каков возможный разброс результата и насколько велика вероятность ошибки в неблагоприятную сторону. В работе были рассмотрены две конфигурации NGBoost: с линейным базовым алгоритмом и с деревьями решений. Такое сравнение удобно с методологической точки зрения. Линейная версия задаёт более простую и интерпретируемую зависимость между признаками и параметрами распределения. Конфигурация на деревьях, наоборот, позволяет учитывать нелинейные эффекты и локальные взаимодействия признаков. Поэтому сопоставление этих вариантов фактически проверяет, есть ли в данных сложная нелинейная структура, которую не удаётся описать линейной моделью.

Практическая часть исследования строилась на временной валидации с расширяющимся окном. Это принципиально важно для финансовых данных. Случайное разбиение наблюдений здесь было бы некорректным, потому что оно может привести к утечке информации из будущего. В схеме расширяющегося окна модель на каждом шаге обучается только на уже доступной истории, а затем проверяется на следующем временном интервале. Такой режим ближе к реальному применению модели: аналитик тоже не знает будущие значения и работает только с теми данными, которые были доступны на момент прогноза.

Для оценки качества использовалось несколько метрик. WMAPE отражала ошибку прогноза в масштабе капитализации. F1 применялась для проверки того, насколько хорошо модель определяет направление изменения показателя. IS показывал согласованность между прогнозными и фактическими доходностями. Такая система метрик важна, потому что финансовый прогноз нельзя нормально оценить одним числом. Модель может давать небольшую ошибку по уровню капитализации, но плохо угадывать направление изменения. Или наоборот — не очень точно предсказывать абсолютное значение, но сохранять

полезный ранжирующий сигнал. Поэтому несколько метрик дают более полную картину качества модели. В прикладных задачах исследователю необходимо одновременно понимать, насколько точен прогноз по уровню, насколько надежно определяется направление движения и содержит ли модель экономически полезный ранжирующий сигнал.

Ключевым результатом работы стало установление устойчивого преимущества конфигурации NGBoostRegressor с деревьями решений над линейной конфигурацией. Сравнение на базовом наборе признаков показало, что использование деревьев решений в качестве базового учителя дает заметный выигрыш по основным метрикам качества. Этот результат имеет принципиальное значение, поскольку он подтверждает наличие выраженной нелинейной структуры в зависимости между признаками и целевой переменной. Иначе говоря, даже в сокращенной постановке задачи исследуемые данные не описываются адекватно в рамках простой линейной спецификации. Влияние признаков меняется в зависимости от контекста, режима рынка, сочетания факторов и уровня самих показателей, а значит, более гибкая нелинейная модель оказывается естественно более подходящей.

Анализ значимости признаков в базовой конфигурации показал, что наибольший вклад в прогноз вносит лаговый рыночный признак, характеризующий предшествующую динамику капитализации. Данный результат является содержательно ожидаемым и согласуется с общими представлениями о финансовых временных рядах: в краткосрочном горизонте инерция и недавнее поведение рынка часто оказываются наиболее сильным источником сигнала. Вместе с тем работа показывает, что доминирование лагового признака не отменяет роли остальных переменных, а лишь указывает на неравномерность распределения прогностической информации. Существенная часть признаков вносит более слабый и менее устойчивый вклад, что особенно отчетливо проявляется в оценках permutation feature importance и IC.

Следующий важный вывод связан с добавлением бухгалтерских признаков к базовому рыночному набору. Проведенные эксперименты показали, что включение отчетности не приводит к существенному приросту качества прогноза и в большинстве случаев лишь незначительно изменяет итоговые значения метрик по сравнению с базовой моделью. Однако не менее важно и то, что добавление части бухгалтерских переменных не

ухудшает предсказательную силу модели. В рамках данной постановки это означает, что роль отчетности состоит не столько в резком усилении точности прогноза, сколько в выявлении экономической составляющей сигнала и в содержательной интерпретации факторов, связанных с фундаментальным состоянием компании. Более детальный анализ показывает, что среди бухгалтерских переменных выделяется подмножество признаков, отражающих рыночную оценку компании относительно фундаментальных показателей, рентабельность, долговую нагрузку, качество собственного капитала, а также ликвидность и особенности инвестиционной политики. Именно эти переменные формируют наиболее интерпретируемую часть фундаментального сигнала. Для полного набора бухгалтерских факторов оценки значимости в среднем действительно оказываются более шумными, чем для главного лагового рыночного признака, однако для отобранных переменных, не ухудшающих качество модели, характерен сравнительно малый разброс важности. Это является существенным преимуществом: даже при умеренной индивидуальной значимости такие признаки демонстрируют относительную устойчивость по временным интервалам и потому могут рассматриваться как надежные носители экономически содержательной информации.

С экономической точки зрения полученные результаты хорошо согласуются с природой исследуемых данных. Рынок реагирует на информацию не только через формальные показатели отчетности, но и через ожидания инвесторов, новостной фон, изменения ликвидности, общее состояние экономики и особенности конкретного рыночного режима. Между возникновением фундаментального сигнала и его полной рыночной капитализацией может существовать временной лаг, а часть этого сигнала может быть заранее встроена в цены. Поэтому отсутствие резкого прироста качества после добавления отчетности следует интерпретировать не как методическую неудачу, а как эмпирически важный результат: в краткосрочном прогнозировании капитализации влияние отчетных данных ограничено и опосредовано, тогда как для более длительных горизонтов оно потенциально может оказаться сильнее.

Практическая значимость работы заключается в том, <sup>1</sup> она позволяет <sup>1</sup> строить реалистичную логику применения методов машинного обучения в задачах анализа финансового состояния компаний. Во-первых, результаты показывают, что в подобных постановках следует уделять особое внимание не только расширению набора признаков, но

и выбору модельной архитектуры. Именно переход к нелинейной конфигурации оказался главным источником прироста качества. Во-вторых, работа демонстрирует, что интерпретация ML-модели должна строиться не только на итоговых метриках, но и на анализе структуры факторов, определяющих прогноз. Это особенно важно в тех случаях, когда модель используется не только как «чёрный ящик» для получения прогноза, но и как инструмент поддержки аналитических и управленческих решений. В такой постановке важно понимать не только итоговое значение прогноза, но и то, какие признаки повлияли на результат. Иначе модель трудно использовать в практическом анализе: прогноз есть, но объяснить его экономически сложно.

Предложенный подход может применяться в прикладных задачах финансового мониторинга. Например, его можно использовать для раннего выявления ухудшения финансового положения компании, инвестиционного скрининга, риск-анализа и корпоративной диагностики. В этих задачах полезны оба результата: сам прогноз и оценка факторов, которые его формируют. При этом у исследования есть ограничения. Прежде всего, после фильтрации данных и построения временной валидации эффективный объём выборки становится меньше исходного массива. Это повышает сопоставимость наблюдений и делает экспериментальную схему более корректной, но одновременно снижает статистическую устойчивость выводов по отдельным признакам. Ещё одно ограничение связано с качеством бухгалтерской информации. Отчётность может содержать пропуски, последующие корректировки, разрывы в данных и методологические различия. Часть таких различий связана с тем, что показатели по РСБУ и МСФО формируются по разным правилам. Поэтому результаты, полученные на бухгалтерских признаках, требуют осторожной интерпретации: они отражают не только экономическое состояние компании, но и особенности раскрытия и подготовки отчётности.

В-третьих, сама интерпретация значимости признаков остается чувствительной к шуму и к конкретным временным интервалам: за пределами нескольких лидирующих факторов ранжирование переменных может меняться, что указывает на эффект распыления сигнала в высокоразмерном пространстве. Все это требует осторожности при формулировании универсальных выводов и подтверждает необходимость дальнейшего совершенствования модели.

В качестве перспектив дальнейшего исследования наиболее логичным представляется переход к сокращенному признаковому пространству, сформированному из наиболее информативных переменных. Такой шаг должен одновременно решить две задачи: повысить интерпретируемость модели и проверить, удастся ли сохранить или улучшить качество прогноза при меньшей размерности. Кроме того, перспективным направлением является более точная синхронизация бухгалтерской отчетности с рыночными данными, учет задержек публикации, а также расширение постановки на другие горизонты прогнозирования. Не исключено, что вклад фундаментальных показателей будет заметно выше в среднесрочном и долгосрочном анализе, чем в задаче краткосрочного прогнозирования капитализации. Дополнительный потенциал связан и с использованием альтернативных источников данных — текстовой корпоративной информации, новостного фона, сигналов из отчетов менеджмента и других неструктурированных признаков.

Итогом работы стало не только сравнение конкретных моделей, но и более общий методический вывод: эффективный анализ финансового состояния компании в современных условиях требует сочетания экономической интерпретации, качественной подготовки данных и гибких ML-инструментов, способных работать с высокоразмерной и неоднородной информацией. В этом смысле поставленная цель исследования достигнута: разработан и обоснован подход к анализу финансовой отчетности на основе методов машинного обучения, выполнено сравнение модельных конфигураций, оценено качество прогноза, исследован вклад различных групп признаков и сформулированы направления дальнейшего развития модели.

## Литература

1. Al-Kassar T., Saadat M., Moloi T., Masadeh A., Al-Hattab A., Jrairah T. The use of accounting and financial ratios to predict failure: The case of Jordan // Academy of Accounting and Financial Studies Journal. — 2019. — Vol. 23, No. 3. — URL: <https://www.abacademies.org/articles/the-use-of-accounting-and-financial-ratios-to-predict-failure-the-case-of-jordan.pdf>
2. Avramov D., Cheng S., Metzker L. Machine Learning versus Economic Restrictions: Evidence from Stock Return Predictability // Working paper. — 2023. — URL: <https://ssrn.com/abstract=4481306>



3. Bondarkov S., Ledenev V., Skougarevskiy D. Russian financial statements database: A firm-level collection of the universe of financial statements // *Scientific Data*. — 2025. — Vol. 12. — Art. 995. — DOI: 10.1038/s41597-025-05150-1 — URL: <https://www.nature.com/articles/s41597-025-05150-1>
4. Bryzgalova S., Pelger M., Zhu J. Forest through the Trees: Building Cross Sections of Stock Returns // *Journal of Finance*. — 2025. — Vol. 80, No. 5. — P. 2447–2506. — DOI: 10.1111/jofi.13477 — URL: <https://onlinelibrary.wiley.com/doi/10.1111/jofi.13477>
5. Chen T. K., Liao H. H., Chen G. D., Kang W. H., Lin Y. C. Bankruptcy prediction using machine learning models with the text-based communicative value of annual reports // *Expert Systems with Applications*. — 2023. — Vol. 233. — Art. 120714. — DOI: 10.1016/j.eswa.2023.120714 — URL: <https://www.sciencedirect.com/science/article/pii/S0957417423012162>
6. Coqueret G., Guida T. *Machine Learning for Factor Investing: Python Version*. — Boca Raton: CRC Press, 2023. — ISBN 978-1-003-12159-6
7. Davis R. A., Nielsen M. S. Modeling of time series using random forests: Theoretical developments // *Annals of Statistics*. — 2020. — Vol. 48, No. 4. — P. 2199–2223. — DOI: 10.1214/19-AOS1875 — URL: <https://doi.org/10.1214/19-AOS1875>
8. Duan T., Avati A., Ding D. Y., Thai K. K., Basu S., Ng A., Schuler A. NGBoost: Natural Gradient Boosting for Probabilistic Prediction // *Proceedings of the 36th International Conference on Machine Learning (ICML 2019)*. — Long Beach, California, USA, 2019. — P. 2690–2700.
9. Gu S., Kelly B., Xiu D. Empirical asset pricing via machine learning // *Journal of Financial Economics*. — 2020. — Vol. 138, No. 3. — P. 622–650. — DOI: 10.1016/j.jfineco.2020.07.006 — URL: <https://www.sciencedirect.com/science/article/pii/S0304405X20301813>
10. Guijo-Rubio D., Middlehurst M., Arcencio G., Furtado Silva D., Bagnall A. Unsupervised feature based algorithms for time series extrinsic regression // *Data Mining and Knowledge Discovery*. — 2023. — Vol. 37, No. 3. — P. 1234–1259. — DOI: 10.1007/s10618-023-00909-5 — URL: <https://link.springer.com/article/10.1007/s10618-023-00909-5>

11. Kelly B. T., Xiu D. Financial machine learning // Working paper. — 2023. — URL: [https://bfi.uchicago.edu/wp-content/uploads/2023/07/BFI\\_WP\\_2023-100.pdf](https://bfi.uchicago.edu/wp-content/uploads/2023/07/BFI_WP_2023-100.pdf)
12. Löning M., Bagnall A., Ganesh S., Kazakov V., Lines J., Király F. J. sktime: A unified interface for machine learning with time series // arXiv preprint. — 2019. — URL: <https://arxiv.org/abs/1909.07872>
13. López de Prado M. Advances in Financial Machine Learning. — Hoboken: Wiley, 2018. — ISBN 978-1-119-49036-9
14. Machete, R. L. Contrasting probabilistic scoring rules. // Journal of Statistical Planning and Inference, 143(10) - 2013 – p. 1781–1790.
15. Mai J., Zhang S., Zhao H., Pan L. Factor investment or feature selection analysis? // Mathematics. — 2024. — Vol. 13, No. 1: 9 — DOI: 10.3390/math13010009 — URL: <https://www.mdpi.com/2227-7390/13/1/9>
16. Martens, J. New insights and perspectives on the natural gradient method. // Technical report. – 2014. - arXiv: 1412.1193.
17. Nagel S. Machine Learning in Asset Pricing. — Princeton, NJ: Princeton University Press, 2021. — 160 p. — ISBN 9780691218700 — DOI: 10.23943/princeton/9780691218717 — URL: <https://doi.org/10.23943/princeton/9780691218717>
18. Nasios I., Vogklis K. Blending gradient boosted trees and neural networks for point and probabilistic forecasting of hierarchical time series // arXiv preprint. — 2023. — DOI: 10.48550/arXiv.2310.13029 — URL: <https://arxiv.org/abs/2310.13029>
19. Nespoli L., Medici V. Multivariate Boosted Trees and Applications to Forecasting and Control // Journal of Machine Learning Research. — 2022. — Vol. 23. — P. 1–35 — URL: <http://jmlr.org/papers/v23/21-0247.html>
20. Ou J. A., Penman S. H. Financial statement analysis and the prediction of stock returns // Journal of Accounting and Economics. — 1989. — Vol. 11, No. 4. — P. 295–329. — DOI: 10.1016/0165-4101(89)90017-7 — URL: <https://www.sciencedirect.com/science/article/pii/0165410189900177>
21. Piotroski J. D. Value investing: The use of historical financial statement information to separate winners from losers // Journal of Accounting Research. — 2000. — Vol. 38, Suppl. — P. 1–41. — DOI: 10.2307/2672906 — URL: <https://www.jstor.org/stable/2672906>

22. Shi C. From Econometrics to Machine Learning: Transforming Empirical Asset Pricing // Journal of Economic Surveys. — 2026. — Vol. 40, No. 1. — P. 528–548 — DOI: 10.1111/joes.70002 — URL: <https://ideas.repec.org/a/bla/jecsur/v40y2026i1p528-548.html>
23. Tan C. W., Bergmeir C., Petitjean F., Webb G. I. Time Series Regression. — 2022. — URL: <https://arxiv.org/abs/2201.11945>
24. Yuan P. Multi-factor Selection and Stock Picking Strategy Based on Random Forest and LightGBM Algorithms. — 2025. — Vol. 1, No. 1 (Issue 6). — DOI: 10.61173/w66yyp49. — URL: <https://aaltodoc.aalto.fi/items/543c8893-91a7-4a61-b4c4-ff42f5283a3c>
25. Волков Д. Л. Управление ценностью: показатели и модели оценки // Российский журнал менеджмента. — 2005. — Т. 3, № 4. — С. 67–76
26. Бухвалов А. В., Волков Д. Л. Фундаментальная ценность собственного капитала: использование в управлении компанией // Научные доклады. — No R1–2005. — СПб.: НИИ менеджмента СПбГУ, 2005
27. Ивашковская И. В. Модели экономической прибыли и контроль создания стоимости компании: дискуссионные вопросы. — 2022

## Приложение

1. Ссылка на программную реализацию: [https://github.com/alexkobz/vmk\\_thesis](https://github.com/alexkobz/vmk_thesis)
2. Признаки, используемые в обучении модели

| Столбец | Наименование | Комментарий |
|---------|--------------|-------------|
|---------|--------------|-------------|

|                                                   |                             |                                                                                                                                      |
|---------------------------------------------------|-----------------------------|--------------------------------------------------------------------------------------------------------------------------------------|
| debt_equity_rsbu,<br>debt_equity_msfo             | Debt / Equity               | Отношение заемного капитала к собственному; отражает степень использования финансового рычага и структуру источников финансирования. |
| debt_ratio_rsbu,<br>debt_ratio_msfo               | Debt Ratio                  | Доля заемного капитала в общей сумме активов; характеризует уровень долговой нагрузки компании.                                      |
| gross_margin_rsbu,<br>gross_margin_msfo           | Валовая рентабельность      | Отношение валовой прибыли к выручке; характеризует эффективность основной производственной деятельности.                             |
| operation_margin_rsbu,<br>operation_margin_msfo   | Операционная рентабельность | Отношение операционной прибыли к выручке; отражает эффективность основной деятельности без учета финансовых и налоговых факторов.    |
| interest_coverage_rsbu,<br>interest_coverage_msfo | Interest Coverage Ratio     | Отношение операционной прибыли к процентным расходам; отражает способность компании обслуживать долговые обязательства.              |
| pbv_rsbu, pbv_msfo                                | P / BV                      | Отношение рыночной капитализации к балансовой стоимости капитала; используется для оценки переоцененности компании рынком.           |
| pcf_rsbu, pcf_msfo                                | P / CF                      | Отношение рыночной капитализации к денежному потоку; отражает способность компании генерировать денежные средства.                   |
| pfcf_rsbu, pfcf_msfo                              | P / FCF                     | Отношение рыночной капитализации к свободному денежному потоку; применяется для оценки инвестиционной привлекательности.             |
| roa_rsbu, roa_msfo                                | ROA                         | Рентабельность активов; характеризует эффективность использования совокупных активов компании.                                       |

|                      |                                                                      |                                                                                                                                                        |
|----------------------|----------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------|
| roce_rsbu, roce_msfo | ROCE                                                                 | Рентабельность задействованного капитала; отражает эффективность использования долгосрочного капитала.                                                 |
| roe_rsbu, roe_msfo   | ROE                                                                  | Рентабельность собственного капитала; характеризует доходность для акционеров.                                                                         |
| line_1240            | Финансовые вложения (за исключением денежных эквивалентов)           | Краткосрочные инвестиции в ценные бумаги и займы.                                                                                                      |
| line_1340            | Переоценка внеоборотных активов                                      | Результаты переоценки основных средств и иных внеоборотных активов.                                                                                    |
| line_1360            | Резервный капитал                                                    | Средства, формируемые в соответствии с законодательством или уставом для покрытия убытков и иных целей.                                                |
| line_2500            | Совокупный финансовый результат периода                              | Суммарный финансовый результат, включающий чистую прибыль и прочие компоненты совокупного дохода.                                                      |
| line_3100            | Величина капитала (2 года назад)                                     | Совокупная величина собственного капитала на начало сравнительного периода.                                                                            |
| line_3210            | Увеличение капитала (1 год назад)                                    | Суммарное увеличение собственного капитала за предыдущий год.                                                                                          |
| line_4200            | Сальдо денежных потоков от инвестиционных операций                   | Чистый поток денежных средств, связанный с инвестиционной деятельностью компании; показывает, сколько денег было потрачено или получено от инвестиций. |
| line_4223            | В связи с приобретением долговых ценных бумаг, предоставление займов | Расходы на инвестиции в облигации, займы другим организациям или физлицам.                                                                             |

### 3. Важность признаков

